




信号与系统实验

主讲人：吴光 博士

Email: wug@sustech.edu.cn



Signals and Systems (Lab)

Project 2: Modulation Classification with Deep Learning

卷积-滤波-卷积核

Dr. **Wu Guang**


wug@sustech.edu.cn

Electrical & Electronic Engineering
Southern University of Science and Technology

Labs in this course


5 Lab assignments+2 Projects

- Lab 1: MATLAB Programming (3 Weeks)
- Lab 2: Linear Time-Invariant Systems (2 Weeks)
- Lab 3: Fourier Series Representation of Periodic Signals (2 Weeks)
- Lab 4: The Continuous-Time Fourier Transform (2 Weeks)
- Lab 5: Coding Test & System, Transform, Convolution and Filter (1 Week)
- Project 1: Motion detection via communication signals (3 Weeks)
- **Project 2: Modulation Classification with Deep Learning (3 Weeks)**




Review: Passive Motion Detection

ISAC: Integrated Sensing And Communications (通信感知一体化)



多天线采集系统



运动检测实验场景

Passive Motion Detection via mmWave Communication System

Abstract—In this paper, an integrated passive sensing and communication system working in 60 GHz band is elaborated, and the sensing performance is investigated in an application of hand gesture recognition. Specifically, in this integrated system, there are two radio frequency (RF) chains at the receiver and one at the transmitter. Each RF chain is connected with one phased array for analog beamforming. To facilitate simultaneous sensing and communication, the transmitter delivers one stream of information-bearing signals via two beam lobes, one is aligned with the main signal propagation path and the other is directed to the sensing target. Signals from the two lobes are received by the two RF chains at the receiver, respectively. By cross ambiguity coherent processing, the time-Doppler spectrograms of hand gestures can be obtained. Relying on the passive sensing system, a dataset of received signals, where three types of hand gestures are sensed, is collected by using Line-of-Sight (LoS) and Non-Line-of-Sight (NLoS) paths as the reference channel respectively. Then a neural network is trained by the dataset for motion detection. It is shown that the classification accuracy rate is high as long as sufficient sensing time is assured. Finally, an empirical model characterizing the relation between the classification accuracy and sensing duration is derived analytically.

I. INTRODUCTION

Integrated Sensing and Communication (ISAC) is a promising technology for the sixth generation cellular system, where the sensing capability has potential to assist the wireless communications and provide new services to subscribers [1], [2]. Compared with sensing of vehicle's velocity and position, human motion sensing is usually more challenging, as the micro-Doppler effect should be captured for classification. Generally, there are three main approaches of wireless human motion sensing in existing ISAC testbed implementations, including wireless sensing via dedicated waves (e.g., Frequency-Modulated Continuous Wave, FMCW), wireless sensing via channel state information (CSI), and passive sensing.

There have been a significant number of works using radar for human motion recognition. For example, in [3], the authors proposed the first coarse multi-person gesture tracking system with FMCW radar, where the direction of a pointing hand can be identified. In [4], Google developed a commercial FMCW-based gesture recognition system, namely the Soli project. In addition, it was shown in [5] that the motion of human skeleton could be reconstructed with recent advances in deep learning.

Compared with integrated radar and communication systems where dedicated time or frequency resources should

be reserved for sensing, there are a number of research works detecting human motion via channel state information (CSI), where the channel sensing does not raise overhead on wireless resource. Particularly, the micro-Doppler effect can also be observed from the variation of the CSI. Moreover, the location of sensing target can be estimated via CSI if multi-antennas and multi-carrier technologies are adopted in the communication system. For example, the CSI was exploited to detect human motions behind the wall in [6]. In [7], the authors explored CSI histograms to recognize daily activities, such as cooking in a kitchen and walking from one room to another, based on empirical study. In [8], the authors proposed theoretical models to derive the relation between CSI and human activities. Recent work [9] jointly estimated the Angle-of-Arrival (AoA), Time-of-Flight (ToF), and Doppler-Frequency-Shift (DFS) for human localization and tracking.

Despite low overhead, CSI-based sensing methods are sensitive to the frequency offset between the transmitter and receiver, which might be a severe problem in millimeter wave (mmWave) band. Although there are methods to eliminate the issue of frequency offset [8], the performance relies on the propagation path without Doppler shift. On the other hand, passive radar is a sensing approach insensitive to the frequency offset. In [10], passive sensing via WiFi signals was adopted to detect the moving personnel. It was further shown in [11] that human breathing behind the wall could be detected via passive sensing. Moreover, the CSI-based sensing and passive sensing were compared in [12]. It was shown that CSI-based system performed better in Line-of-Sight (LoS) scenarios, while passive radar system performed better in Non-Line-of-Sight (NLoS) scenarios.


Although there have been a number of testbeds and experiment results on the passive sensing in sub-6 GHz band, there is still no passive sensing testbed in mmWave band. Note that communications in mmWave band has already been considered in the 5G cellular system and IEEE 802.11ay systems, it is natural to extend the passive sensing technique to mmWave band. Moreover, because of the smaller wavelength, sensing in mmWave band would have higher Doppler resolution.

In this paper, 60 GHz mmWave communication and passive sensing system implementation is elaborated. The 16-antenna phased arrays are deployed at both the transmitter and receiver, so that the mmWave signal transmission can be directed to the sensing target to suppress the interference from LoS path. The performance of the above system is investigated via the exemplary application of hand gesture recognition. Specifically, a dataset of received signals of three gestures is provided and


Review: Passive Motion Detection

- 了解实验目标
- 激发实验兴趣
- 融入思政内容

- 多径效应
- 多普勒频移
- 参考信道模型
- 监视信道模型
- 模糊函数
- 数字下变频
- 数字低通滤波器
- 距离/时间-多普勒谱



Human Motion Detection




Output Waveform



Aircraft Detection

Principle

On-Line/Off-Line



本次实验



Project 2: Modulation Classification with Deep Learning

Dr. Wu Guang
wug@sustech.edu.cn

Electrical & Electronic Engineering
Southern University of Science and Technology

教学实施进程

- 了解实验目标
- 激发实验兴趣
- 融入思政内容
- 数字/模拟调制
- 多径效应
- 多普勒频移
- 卷积神经网络
- 卷积核
- 激活函数
- 全连接层
- 混淆矩阵






以认知电子战为例，
融入思政

原理讲解

SDR信号采集

线下/线上



1.1 无线电通信干扰识别


- **军事领域：**主要用在电子战，有利于干扰/抗干扰通信技术的实现。
- 无线电通信干扰：运用无线电干扰设备发射适当的干扰电磁波，破和扰乱敌方无线电通信的通信对抗技术，目的是使敌方无线电通信中断、指挥失灵，或使敌方通信联络困难。
- 典型的干扰系统有：俄军在俄乌边境地区部署的“摩尔曼斯克-BN”综合电子战系统，美军陆军电子战战术车辆系统(EWTV)等。
- **民用领域：**用于政府频谱监管，重点区域干扰源类型判断。
- 日益增长通信需求使得无线电热点急剧增加，随之而来的无线电干扰类型、发射器类型需要有效识别和管控。
- 在最新的动态频谱访问（DSA）技术中，一个关键的感知任务是获取周围发射器的感知，以避免无线电干扰并优化频谱分配。这意味着识别和区分广播无线电、本地和广域数据和语音无线电、雷达用户以及其他可能引起无线电干扰的来源，它们各自具有不同的行为和要求。其中，调制识别的目标是将接收到的无线电信号的调制类型进行分类，这是了解干扰源通信方案和发射器类型的关键一步。



1.2 人工智能和认知电子战


近年来，随着人工智能技术的飞速发展，许多研究将深度学习应用于通信领域。

- 2010年以来，美军为提高电子战作战效能，**逐步地将认知的概念引入到电子战装备中**。例如，美军开展的认知电子战项目有：自适应雷达对抗、自适应电子战行为学习、极端射频频谱条件下的通信、美空军认知干扰机、美空军先进电子战组件、美海军认知通信电子战、美海军下一代电子战技术。
- 2016年，O'shea 及其团队连续发表多篇论文，研究**深度学习技术在无线电通信与识别领域应用**的方法与问题，开启了无线电识别从经验驱动的人造特征范式到数据驱动的代表学习范式的新纪元。
- 2016年，美国国防部高级研究计划局（DARPA）宣布启动 SC2 挑战赛，旨在“**将先进的机器学习能力应用于无线电领域**，优化频谱使用策略，以缓解电磁频谱拥挤状态”。
- 2017年同年8月，DARPA 启动了射频机器学习系统（RFMLS）项目。作为SC2项目的补充，RFMLS项目旨在“建立一种射频鉴别能力，能够从信号嘈杂聚集的频谱中分辨出独特和特殊的信号”，未来将应用于民用和军事领域。




1.3 认知电子战中的调制识别问题

- 早期的无线电信号识别技术：首先采集射频信号，然后经过信号处理处理，以频谱图、瀑布图等可视化的方式展现，最后由专业人员分析信号时频特征并寻找目标信号。这种方式不仅对操作人员的专业素质要求高，而且当监测时间变长或无线电信号较多时，人工分析效率和准确率也会大幅下降。
- 当前的无线电信号识别技术：将**人工智能与传统无线电信号识别技术深度融合**，利用人工智能的机器学习方法，特别是深度学习算法，自动提取无线电波的模式特征，避免基于经验的人工特征提取，提高无线电信号的识别能力。
- 早在20世纪90年代，传统机器学习算法，如朴素贝叶斯、神经网络、决策树等，已经在无线电调制识别领域中得到了应用，但受限于当时的技术发展水平，仅利用机器学习算法根据人工提取出的信号特征进行分类，具体流程如图所示。



1.4 基于CNN网络的调制识别--MATLAB案例



The screenshot shows the MATLAB Help Center interface. The main content area is titled "Modulation Classification with Deep Learning" and includes a description of the example, a list of modulation types recognized by the CNN, and a link to the live script. A red box highlights the list of modulation types, and a blue callout box points to it with a summary statement.

Help Center 搜索 R2022b 文档

Documentation Examples Functions Blocks Apps

Modulation Classification with Deep Learning R2022b

This example shows how to use a convolutional neural network (CNN) for modulation classification. You generate synthetic, channel-impaired waveforms. Using the generated waveforms as training data, you train a CNN for modulation classification. You then test the CNN with software-defined radio (SDR) hardware and over-the-air signals.

Predict Modulation Type Using CNN

The trained CNN in this example recognizes these eight digital and three analog modulation types:

- Binary phase shift keying (BPSK)
- Quadrature phase shift keying (QPSK)
- 8-ary phase shift keying (8-PSK)
- 16-ary quadrature amplitude modulation (16-QAM)
- 64-ary quadrature amplitude modulation (64-QAM)
- 4-ary pulse amplitude modulation (PAM4)
- Gaussian frequency shift keying (GFSK)
- Continuous phase frequency shift keying (CPFSK)
- Broadcast FM (B-FM)
- Double sideband amplitude modulation (DSB-AM)
- Single sideband amplitude modulation (SSB-AM)

This example uses:
[Communications Toolbox](#)
[Deep Learning Toolbox](#)

[Open Live Script](#)


```
modulationTypes = categorical(["BPSK", "QPSK", "8PSK", ...  
    "16QAM", "64QAM", "PAM4", "GFSK", "CPFSK", ...  
    "B-FM", "DSB-AM", "SSB-AM"]);
```

基于MATLAB，利用CNN实现11种不同类型的调制方式分类。

O'Shea, T. J., J. Corgan, and T. C. Clancy. "Convolutional Radio Modulation Recognition Networks." Preprint, submitted June 10, 2016.

1.5 运行MATLAB案例程序

➤ 实验步骤:


- 1、打开实时脚本（注意需要安装通信工具箱和深度学习工具箱）
- 2、在程序第61行设置一个断点 ;
- 3、随机设置调制方式，观察基于CNN网络的识别概率。

This example uses:


Communications Toolbox

Deep Learning Toolbox

Open Live Script




PAM4




QPSK

```
d = randi([0 3], 1024, 1);  
syms = pskmod(d,4);
```



8-PSK

```
d = randi([0 7], 1024, 1);  
syms = pskmod(d,8);
```



64-QAM

```
d = randi([0 63], 1024, 1);  
syms = pskmod(d,64);
```


1.6 课堂练习-1

➤ 课堂练习:

- 1、核对是否已经完成深度学习工具箱（Deep Learning Toolbox）安装
- 2、设调制方式分别为BPSK、16-QAM、64-QAM、GFSK、CPFSK、B-FM、DSB-AM、SSB-AM，画出对应的识别概率图，并且在Blackboard系统课堂实时提交。
- 3、步入函数：helperModClassGetNNFrames、classify，根据MATLAB给出的说明，了解函数功能。

```
function y = FMmodulation(spf,fs)
audioSrc = dsp.AudioFileReader('audio_mix_441.wav','SamplesPerFrame',spf,'PlayCount',inf);
audioRC = dsp.SampleRateConverter('Bandwidth',30e3, 'InputSampleRate',audioSrc.SampleRate, 'OutputSampleRate',fs);
[~,decimFactor] = getRateChangeFactors(audioRC);
audioSrc.SamplesPerFrame = ceil(spf / fs * audioSrc.SampleRate / decimFactor) * decimFactor;
x = audioRC(audioSrc());
mod = comm.FMBroadcastModulator('AudioSampleRate', fs, 'SampleRate', fs);
y = mod(x);
end
```

1.7 运行MATLAB案例程序--流程图



1.8 深度学习算法中使用的帧

helperModClassFrameGenerator: 生成用于深度学习网络接收的帧

`Y=helperModClassFrameGenerator (X、WLEN、STEP、OFFSET、SPS)`

对输入X进行分段，以生成要在深度学习算法中使用的帧，X必须是复值列向量。

输出Y是一个大小WLENxN复值数组，其中N是输出帧数。

每个单独的帧都有WLEN个样本点，该窗口为新帧的STEP采样。STEP可以小于或大于WLEN。


在基于offset值计算初始偏移后，函数对输入X进行分段。OFFSET是指定为实值标量的确定性偏移值。

SPS是每个符号的采样数。总偏移量为offset+randi ([0 SPS]) 样本。这个偏移的确定性部分消除了瞬态，而随机部分使网络能够适应未知的延迟值。

每帧被归一化为具有单位能量。

```
I = permute(real(framesComplex), [3 1 4 2])
```

1024*7



取列向量，每个列向量独立成一个向量

1.9 分类--classify

```
>> trainedNet.Layers
```

```
ans =
```

具有以下层的 28×1 Layer 数组:

```
[prediction1,score1] = classify(trainedNet, unknownFrames)
```

利用CNN网络对输入数据进行分类，返回预测的分类，以对应的得分。


trainedNet表示已经训练好的CNN网络

unknownFrames表示上一步分隔后的帧（7个）


1	'Input Layer'	图像输入	1×1024×2 图像
2	'CNN1'	二维卷积	16 1×8×2 卷积: 步幅 [1 1], 填充 'same'
3	'BN1'	批量归一化	批量归一化: 16 个通道
4	'ReLU1'	ReLU	ReLU
5	'MaxPool1'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
6	'CNN2'	二维卷积	24 1×8×16 卷积: 步幅 [1 1], 填充 'same'
7	'BN2'	批量归一化	批量归一化: 24 个通道
8	'ReLU2'	ReLU	ReLU
9	'MaxPool2'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
10	'CNN3'	二维卷积	32 1×8×24 卷积: 步幅 [1 1], 填充 'same'
11	'BN3'	批量归一化	批量归一化: 32 个通道
12	'ReLU3'	ReLU	ReLU
13	'MaxPool3'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
14	'CNN4'	二维卷积	48 1×8×32 卷积: 步幅 [1 1], 填充 'same'
15	'BN4'	批量归一化	批量归一化: 48 个通道
16	'ReLU4'	ReLU	ReLU
17	'MaxPool4'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
18	'CNN5'	二维卷积	64 1×8×48 卷积: 步幅 [1 1], 填充 'same'
19	'BN5'	批量归一化	批量归一化: 64 个通道
20	'ReLU5'	ReLU	ReLU
21	'MaxPool5'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
22	'CNN6'	二维卷积	96 1×8×64 卷积: 步幅 [1 1], 填充 'same'
23	'BN6'	批量归一化	批量归一化: 96 个通道
24	'ReLU6'	ReLU	ReLU
25	'AP1'	二维平均池化	1×32 平均池化: 步幅 [1 1], 填充 [0 0 0 0]
26	'FC1'	全连接	11 全连接层
27	'SoftMax'	Softmax	softmax
28	'Output'	分类输出	crossentropyex: 具有 '16QAM' 和 10 个其他类

1.10 分类--helperModClassPlotScores


helperModClassPlotScores(score1,modulationTypes)



QPSK



8-PSK





64-QAM

从上图可以看出：每种调制方式均存在一定的错误预测概率。同种调制方式的不同帧也会存在一定的误判。

教学实施进程

- 了解实验目标
- 激发实验兴趣
- 融入思政内容
- 数字/模拟调制
- 多径效应
- 多普勒频移
- 卷积神经网络
- 卷积核
- 激活函数
- 全连接层
- 混淆矩阵






以认知电子战为例，
融入思政

原理讲解

SDR信号采集

线下/线上



2.1 图像特征--Feature

Feature: A feature of something is an interesting or important part or characteristic of it.

特征是某些突出性质的表现，也是区分事物的关键，当我们要对事物进行分类或者识别时，实际上就是提取‘特征’，通过特征的表现进行判断。

例如，当我们看到一个动物有黑白相间的条纹时，我们很容易将其分类为斑马。

这种“黑白相间的条纹”，就是斑马的特征。

再如，当我们看到一个动物一身白色皮毛，且生活在海洋冰雪之中时，我们很容易将其归类为北极熊。


这种“一身白色皮毛，且生活在海洋冰雪”便是北极熊的特征。



2.2 图像特征--Feature

因此，我们识别一幅图像的过程，本质是寻找图像特征的过程。

例如，我们要识别这张图片里的字母是X还是O，可以通过其局部特征来判断。





字母X，有3个局部特征，具有A、B形状的“腿”，就有C形状的“心”。

实际的图像可能是由X经过平移、缩放、或者旋转得到的，但是它们的“局部特征”基本没变。这为卷积神经网络（CNN）分类方法的实现奠定了基础。

2.3 图像特征--Feature

卷积神经网络（Convolutional Neural Networks, CNN）的主要目标，就是从这些图片中，提取内容为X图片的特征。

图片X在计算机内部以像素值的方式被存储，如图所示，其中1代表白色，-1代表黑色。




如果识别一张照片是否为X，但是CNN不知道什么是X，就得告诉它：X有A，B，C三个特征，且A、B、C分别是什么样，只要CNN去搜索整张图，找到这三个特征，就可以判断是否为X。

2.4 卷积核--Filter

从标准的X图中提取出特征，在CNN中也被成为卷积核（filter），一般是3X3，或者5X5大小。

卷积核的作用类似于信号与系统中的滤波器，增强兴趣区域强度，衰减非兴趣区域强度。



2.5 CNN中的卷积运算过程


卷积运算过程：

- 1、将卷积核置于待处理图片之上，重叠的元素相乘并相加，将得到卷积值，求平均，得到一个均值，将均值填入特征图中；
- 2、移动卷积核，重复步骤1；
- 3、计算三个卷积核对应的特征图

在第2步中，卷积中对应相乘运算并求得均值后，滑动窗便开始向右边滑动。根据步长的不同选择滑动幅度。若步长等于1，就往右平移一个像素。

说明：CNN中定义的卷积和信号中的卷积不一样。但本质是一样的。信号中的卷积，或者说是滤波，实际是根据滤波器的特征，对信号中期望频率进行处理。

CNN中的卷积，目的是对图像中包含特征的部分进行增强处理。



2.6 CNN中的卷积过程

特征图是每一个卷积核从原始图像中提取出来的“特征”。其中的值，越接近为1表示对应位置和feature的匹配越完整，越是接近-1，表示对应位置和feature的反面匹配越完整，而值接近0的表示对应位置没有任何匹配或者说没有什么关联。

一个卷积核作用于图片产生一张特征图，对这张x图来说，用的是3个卷积核，最终产生3个特征图。



2.7 非线性激活函数--Relu函数

卷积层对原图运算多个卷积产生一组线性激活响应，而非线性激活层是对之前的结果进行一个非线性的激活响应。



在神经网络中用到最多的非线性激活函数是Relu函数，它的公式定义如下：

$$f(x)=\max(0,x)$$

即，保留大于等于0的值，其余所有小于0的数值直接改写为0。

卷积后产生的特征图中的值，越靠近1表示与该特征越关联，越靠近-1表示越不关联，进行特征提取时，为了使得数据更少，操作更方便，就直接舍弃掉那些不相关联的数据。

如图所示： ≥ 0 的值不变；而 < 0 的值一律改写为0





2.8 最大池化--Max Pooling

卷积操作后，得到了特征图，但数据量过于庞大，因此接下来的池化操作就可以发挥作用了，它最大的目标就是减少数据量。**CNN**目标是发现图像中是否具有某种特征，而不用在意到底在哪里具有这种特征。

池化分为两种，**Max Pooling**最大池化、**Average Pooling**平均池化。最大池化就是取最大值，平均池化就是取平均值。

例如：选择池化尺寸为2x2，因为选定一个2x2的窗口，在其内选出最大值更新进新的特征图。



2.9 多层网络结构

在常见的几种CNN中，这三层都是可以堆叠使用的，将前一层的输入作为后一层的输出。



在本实验中，总共有28层。含输入层和输出层。

中间层依次进行二维卷积、非线性激活、最大值池化，并且通过6次处理。

1	'Input Layer'	图像输入	1×1024×2 图像
2	'CNN1'	二维卷积	16 1×8×2 卷积: 步幅 [1 1], 填充 'same'
3	'BN1'	批量归一化	批量归一化: 16 个通道
4	'ReLU1'	ReLU	ReLU
5	'MaxPool1'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
6	'CNN2'	二维卷积	24 1×8×16 卷积: 步幅 [1 1], 填充 'same'
7	'BN2'	批量归一化	批量归一化: 24 个通道
8	'ReLU2'	ReLU	ReLU
9	'MaxPool2'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
10	'CNN3'	二维卷积	32 1×8×24 卷积: 步幅 [1 1], 填充 'same'
11	'BN3'	批量归一化	批量归一化: 32 个通道
12	'ReLU3'	ReLU	ReLU
13	'MaxPool3'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
14	'CNN4'	二维卷积	48 1×8×32 卷积: 步幅 [1 1], 填充 'same'
15	'BN4'	批量归一化	批量归一化: 48 个通道
16	'ReLU4'	ReLU	ReLU
17	'MaxPool4'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
18	'CNN5'	二维卷积	64 1×8×48 卷积: 步幅 [1 1], 填充 'same'
19	'BN5'	批量归一化	批量归一化: 64 个通道
20	'ReLU5'	ReLU	ReLU
21	'MaxPool5'	二维最大池化	1×2 最大池化: 步幅 [1 2], 填充 [0 0 0 0]
22	'CNN6'	二维卷积	96 1×8×64 卷积: 步幅 [1 1], 填充 'same'
23	'BN6'	批量归一化	批量归一化: 96 个通道
24	'ReLU6'	ReLU	ReLU
25	'AP1'	二维平均池化	1×32 平均池化: 步幅 [1 1], 填充 [0 0 0 0]
26	'FC1'	全连接	11 全连接层
27	'SoftMax'	Softmax	softmax
28	'Output'	分类输出	crossentropyex: 具有 '16QAM' 和 10 个其他类

2.10 全连接层

原图片尺寸为9X9，在一系列的卷积、非线性激活、池化操作后，得到尺寸被压缩为2X2的三张特征图。



全连接层：对特征图进行维度上的改变，来得到每个分类类别对应的概率值。



卷积层采用的是“局部连接”的思想，是用一个3X3的图与原图进行连接操作，很明显原图中只有一个3X3的窗口能够与它连接起来。

2.11 全连接层

得到了 2×2 的特征图后，对其应用全连接网络，再全连接层中有一个非常重要的函数----Softmax，它是一个分类函数，输出的是每个对应类别的概率值。

注意:本例中因为只有两个类别X和O，而且数据量到此已经非常少了，因此直接将三个特征图改变维度直接变成一维的数据，相当于全连接层的每个参数均为1。

展开的数据即为属于类别X的概率值，值大小也在对应X的线条粗细中表现出来了。





2.12 全连接层

非标准图像计算结果






0.9表示极其大可能是x，因此对应到x的黄色线条比对应到O的绿色线条要粗很多很多。

对结果进行统计分析后可判断这张图片里的字母为x。



教学实施进程

- 了解实验目标
- 激发实验兴趣
- 融入思政内容
- 数字/模拟调制
- 多径效应
- 多普勒频移
- 卷积神经网络
- 卷积核
- 激活函数
- 全连接层
- 混淆矩阵



3.1 训练卷积神经网络


波形训练

对于各种调制类型，产生400个帧数据，80%用于训练，10%用于评估网络，10%用于测试。开始用训练和评估帧，最后分类测试用测试帧。



- 单帧长度是1024个采样，
- 采样率为200kHz，
- 数字调制，8个采样表示一个符号，
- 数字信号的中心频率是902MHz，
- 模拟信号的中心频率是100MHz，
- 为了获得CNN网络，选择"Train network now"

```
trainNow =  ;  
if trainNow == true  
    numFramesPerModType = 400;  
else  
    numFramesPerModType = 200;  
end  
  
percentTrainingSamples = 80;    % 训练集: 训练模型  
percentValidationSamples = 10;  % 验证集: 评估模型  
percentTestSamples = 10;       % 测试集: 一旦找到了最佳参数, 就开始最终训练  
  
sps = 8;                       % 每个符号8个采样  
spf = 1024;                    % 每帧1024个采样  
symbolsPerFrame = spf / sps;  % 每帧128个采样  
fs = 200e3;                    % 采样率为200kHz  
fc = [902e6 100e6];            % 中心频率, 数字调制902MHz, 模拟调制100MHz
```



3.2 训练卷积神经网络--流程图



3.3 训练卷积神经网络--混淆矩阵



3.4 训练卷积神经网络--混淆矩阵



课后作业-2

➤ 课后作业:

- 1、画出以下函数的流程图: `helperModClassFrameGenerator`、`helperModClassFrameGenerator`
- 2、画出以下函数的流程图: `classify`

Question ?

