


第六章 数理统计的基本概念与抽样分布

§ 1 引 言

§ 2 基本概念

§ 3 抽样分布





什么叫数理统计

数理统计是以概率论为理论基础, 关于实验数据的收集、整理、分析、推断的一门数学学科

实际背景

例 某工厂生产了一大批产品, 从中随机抽检了 n 件产品, 发现有 m 件次品, 如何估计整批产品的次品率 p ?

例 要求某种元件的平均使用寿命不得低于1000小时, 现从这批元件中随机抽取25件, 测得其寿命的平均值为950小时. 试问该批元件是否达到了要求?

统计推断的基本内容

点估计

非参数假设检验

区间估计

方差分析

参数假设检验

回归分析



●问 什么是实验数据?

科学试验，或对某事物、现象进行观察获得的数据称为**实验数据**。

特点 数据受随机因素的影响


●问 处理实验数据的过程?

收集、整理、分析、推断

《数理统计》围绕这四个过程来进行研究

●问 如何收集和整理数据?

本章将研究“收集”和“整理”数据的数学含义



数理统计的几个基本概念

总体 研究对象的全体称为总体

个体 总体中的一个具体对象称为个体


例 考察某班级学生的英语课程学习成绩, 则全体学生构成了一个总体, 每个同学就是一个个体?

例 考察某工厂生产的某批灯泡的寿命, 则该厂生产的该批灯泡构成了一个总体, 每个灯泡就是一个个体?



问题 这样定义的总体和个体是具体的对象, 不符合数学研究的特点——抽象

如何改进?



数理统计的几个基本概念

总体 研究对象的全体称为总体

个体 总体中的一个具体对象称为个体

例 考察某班级学生的英语课程学习成绩, 则全体学生构成了一个总体, 每个同学就是一个个体?

例 考察某工厂生产的某批灯泡的寿命, 则该厂生产的该批灯泡构成了一个总体, 每个灯泡就是一个个体?

不是研究它们

而是研究数量指标

这些数量指标是服从某种分布的r.v



数理统计的几个基本概念

总体 研究对象的全体称为总体

个体 总体中的一个具体对象称为个体

例 考察某班级学生的英语课程学习成绩, 则全体学生构成了一个总体, 每个同学就是一个个体.

例 考察某工厂生产的某批灯泡的寿命, 则该厂生产的该批灯泡构成了一个总体, 每个灯泡就是一个个体.

总体: 研究对象的数量指标 $X \sim F(x)$

个体: r.v X 的值



例 考察某班级学生的英语课程学习成绩 X , 因为每个学生的成绩都在全班平均成绩 μ 的附近波动, 所以总体可视为 $X \sim N(\mu, \sigma^2)$.

例 考察某工厂生产的某批灯泡的寿命 X , 因为每个灯泡的寿命都在该批灯泡平均寿命 μ 的附近波动, 所以总体可视为 $X \sim N(\mu, \sigma^2)$.

例 考察某工厂生产的零件是否合格, 记

$$X = \begin{cases} 0, & \text{零件合格} \\ 1, & \text{零件不合格} \end{cases}$$

则总体可视为 $X \sim b(1, p)$, p 为零件的次品率.



问 如何收集数据?

从研究对象中任取 n 个“个体”，观察它们的数量指标

$$X_1, X_2, \dots, X_n$$

这一过程称为**抽样**， $X_1, X_2, \dots, X_n$ 称为**容量为 n 的样本**。

抽样的特点

在相同条件下对总体 X 进行 n 次重复、独立观察

独立性：要求各次取样的结果互不影响

代表性：每次取出的样品与总体有相同的分布


样本的特点

观察前： $X_1, X_2, \dots, X_n$ 是相互独立，与总体同分布的r.v

观察后：样本值 $x_1, x_2, \dots, x_n$ n 个具体的观察数据

样本的二重性

样本观察值



例 某厂生产了一大批灯泡, 现从中随机抽取5只进行检测, 测得其寿命(小时)分别为

980, 960, 1030, 1300, 850

分析 总体为灯泡的寿命

$$X \sim N(\mu, \sigma^2)$$

连续型总体

样本容量为5, 样本为 X_1, X_2, X_3, X_4, X_5

样本观察值为 980, 960, 1030, 1300, 850

样本二重性

例 对长度为 μ 的工件进行了6次测量, 测量值为

29.1, 30.2, 29.3, 29.1, 30.3, 29.5

分析 总体为工件长度

$$X \sim N(\mu, \sigma^2)$$

样本容量为6, 样本为 $X_1, X_2, X_3, X_4, X_5, X_6$

样本观察值为 29.1, 30.2, 29.3, 29.1, 30.3, 29.5

样本二重性



例 考察某工厂生产的零件是否合格,从该厂生产的一批产品中随机抽检了100个,若合格则记为0,若不合格则记为1, 100个产品的检查结果为 $x_1, x_2, \dots, x_{100}$.

分析 总体 $X \sim b(1, p)$ (零件合格或不合格)

总体频率函数为

$$P\{X = 1\} = p, P\{X = 0\} = 1 - p$$

其中 p 为零件的次品率.

二重性 $\left\{ \begin{array}{l} \text{样本 } X_1, X_2, \dots, X_{100} \text{ (独立同分布(0-1)分布r.v)} \\ \text{样本观察值 } x_1, x_2, \dots, x_{100}. \end{array} \right.$


离散型总体



对样本的一些认识

设 $X_1, X_2, \dots, X_n$ 是来自总体 $X \sim F(x)$ 的样本

- ❶ $X_1, X_2, \dots, X_n$ 是一堆 “杂乱无章” 的数据
- ❷ $X_1, X_2, \dots, X_n$ 包含了有关总体的 “信息”
- ❸ $X_1, X_2, \dots, X_n$ 是对总体进行推断的依据
- ❹ 在观察前 $X_1, X_2, \dots, X_n$ 是一组独立同分布r.v
在观察后 $x_1, x_2, \dots, x_n$ 是一组具体的数据



样本的分布

问题 样本 $X_1, X_2, \dots, X_n$ 作为多维随机变量，服从什么分布？

1. 若总体分布函数为 $F(x)$ ，则样本联合分布函数为

$$F^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

2. 若总体密度函数为 $f(x)$ ，则样本联合密度函数为

$$f^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

例 设 $X_1, X_2, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的样本，则样本分布密度函数为

$$f^*(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(\sqrt{2\pi}\sigma)^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

n 维正态分布



例 设 $X_1, X_2, \dots, X_n$ 为来自总体 $X \sim b(1, p) (0 < p < 1)$ 的样本, 求样本分布.

解 总体的频率函数
为

$$P(X=1)=p, \quad P(X=0)=1-p$$

样本 $X_1, X_2, \dots, X_n$ 是独立同服从(0-1)分布的随机变量,
因此样本分布为


$$\begin{aligned} P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \end{aligned}$$



总体、样本、样本值的关系

事实上我们抽样后得到的资料都是具体的、确定的值。如我们从某班大学生中抽取10人测量身高，得到10个数，它们是样本取到的值而不是样本。我们只能观察到随机变量取的值而见不到随机变量。





统计是从手中已有的资料--样本值，去推断总体的情况---总体分布 $F(x)$ 的性质.

样本是联系二者的桥梁

总体分布决定了样本取值的概率规律，也就是**样本**取到**样本值**的规律，因而可以由**样本值**去推断**总体**.



● 统计推断的基础：收集数据

从总体 $X \sim F(x)$ 抽取样本

$$X_1, X_2, \dots, X_n$$

“杂乱无章”的数据


包含了各种有用的“信息”

 **问** 怎样集中、提炼出有用的信息？

例 某班级《高等数学》课程考试成绩单列出 n 个学生成绩分别为 $X_1, X_2, \dots, X_n$. 如何评价全班整体学习情况？

分析 下面的量能较好地反映全班整体学习情况

$$\frac{1}{n} \sum_{i=1}^n X_i, \max_{1 \leq i \leq n} X_i, \min_{1 \leq i \leq n} X_i$$



● 统计推断的基础：收集数据

从总体 $X \sim F(x)$ 抽取样本

$$X_1, X_2, \dots, X_n$$


“好”统计量能够有效地提炼出数据中包含的有用信息

● 数据的加工整理：统计量

设 $X_1, X_2, \dots, X_n$ 为来自总体 $X \sim F(x)$ 的样本, $g(x_1, x_2, \dots, x_n)$ 为 n 元函数, 若 r.v $g(X_1, X_2, \dots, X_n)$ 不含任何未知参数, 则称 $g(X_1, X_2, \dots, X_n)$ 为 **统计量**.

● 统计量的二重性

- ① 试验前 $g(X_1, X_2, \dots, X_n)$ 是随机变量
- ② 试验后 $g(x_1, x_2, \dots, x_n)$ 是具体的数值



常用的统计量

与均值和方差
有什么不同?

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

为什么不是 $\frac{1}{n}$ (后续说明)

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

与第4章介绍的
矩有什么不同?

样本k阶矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k = 1, 2, \dots)$$

样本k阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k = 1, 2, \dots)$$

将样本 $X_1, X_2, \dots, X_n$ 由小到大排列为 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$

顺序统计量 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$

极小值 $X_{(1)} = \min\{X_1, X_2, \dots, X_n\}$

极大值 $X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$



样本矩的特性

设 $X_1, X_2, \dots, X_n$ 为来自总体 $X \sim F(x)$ 的样本, 总体 k 阶矩

$$\mu_k \triangleq E(X^k) \quad (k = 1, 2, \dots)$$

都存在.

① $\because X_1, X_2, \dots, X_n$ 独立, 与总体同分布

$\therefore X_1^k, X_2^k, \dots, X_n^k$ 独立, 与 X^k 同分布

$$\textcircled{2} \quad E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \frac{1}{n} \sum_{i=1}^n E(X^k) = \mu_k \quad (k = 1, 2, \dots)$$

③ 由辛钦大数定律知 $\forall k = 1, 2, \dots$

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, \quad n \rightarrow \infty$$

$$g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k), \quad n \rightarrow \infty$$

其中 g 为连续函数.



样本均值与样本方差的数字特征

设总体 X 的均值和方差

$$E(X) \triangleq \mu, D(X) \triangleq \sigma^2$$

都存在. $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 则

$$E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}, E(S^2) = \sigma^2$$

证 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{\sigma^2}{n}$$

$$\begin{aligned} \because (n-1)S^2 &= \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n [(X_i - \mu) + (\mu - \bar{X})]^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n(\mu - \bar{X})^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2n(\bar{X} - \mu)^2 + n(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \end{aligned}$$



样本均值与样本方差的数字特征

设总体 X 的均值和方差

$$E(X) \triangleq \mu, D(X) \triangleq \sigma^2$$

都存在. $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 则

$$E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}, E(S^2) = \sigma^2$$

证 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{\sigma^2}{n}$$

$$\therefore (n-1)S^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

$$\begin{aligned} \therefore (n-1)E(S^2) &= \sum_{i=1}^n E(X_i - \mu)^2 - nE(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n \sigma^2 - n \frac{\sigma^2}{n} = (n-1)\sigma^2 \end{aligned}$$

$$\therefore E(S^2) = \sigma^2$$



样本均值与样本方差的实际意义

$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ —— 是全体实验数据 $X_1, X_2, \dots, X_n$ 的平均值，
是数据 $X_1, X_2, \dots, X_n$ 的中心

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ —— 反映了实验数据 $X_1, X_2, \dots, X_n$ 与数据
中心的偏离程度，反映了全体实验
数据 $X_1, X_2, \dots, X_n$ 的离散程度

 **思考** $E(\bar{X}) = \mu$, $D(\bar{X}) = \frac{\sigma^2}{n}$, $E(S^2) = \sigma^2$ 说明了什么？



定理（辛钦大数定律） 设 $\{X_n\}$ 是独立同分布 r. v 列, $E(X_1) \triangleq \mu$ 存在, 则 $\{X_n\}$ 服从大数定律, 即 $\forall \varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| < \varepsilon\right\} = 1$$

或

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| \geq \varepsilon\right\} = 0$$

BACK