

Contents

1	Chapter1: 概率	2
2	Chapter2: 随机变量	6
3	Chapter3: 联合分布	11
4	Chapter4: 随机变量的数字特征	16
5	Chapter5: 大数定律与中心极限定理	20
A	几个常见卷积公式	21
A.1	泊松分布的可加性:	21
A.2	二项分布的可加性:	22
A.3	正态分布的可加性:	23
A.4	Gamma 分布的可加性:	24
B	常见随机变量的数学期望及方差	25

1 Chapter1: 概率

■ 基本概念:

1. 随机现象: 在一定的条件下, 并不总是出现相同结果的现象称为**随机现象**.
2. 试验: 对于在相同条件下可以重复的随机现象的观察、记录、实验称为**随机试验**, 或**试验**.
3. 样本空间: 随机现象的一切可能基本结果组成的集合称为**样本空间**, 记为 $\Omega = \{\omega\}$, 其中 ω 表示基本结果, 又称为**样本点**. 样本点是今后抽样的最基本单元.

★几个注意点:

- 样本空间中的元素可以是数也可以不是数: e.g. 抛一枚硬币的样本空间为 $\Omega_1 = \{\omega_1, \omega_2\}$, 其中 ω_1 表示正面朝上, ω_2 表示反面朝上.
- 样本空间至少有两个点, 否则不具有随机性.
- 我们将样本点的个数为有限个或可列个的样本空间称作**离散样本空间**, e.g. 掷一颗骰子的样本空间 $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, 或一天内进入某商场的顾客数的样本空间 $\Omega_3 = \{0, 1, 2, \dots, 500, \dots, 10^4, \dots\}$; 将样本点的个数为不可列无限个的样本空间称作**连续样本空间**, e.g. 电视机寿命的样本空间 $\Omega_4 = \{t | t \geq 0\}$.
- 4. 事件: 随机现象的某些样本点组成的集合称为**随机事件**, 或**事件**. 常用大写字母表示 $A, B, \dots$

★几个注意点:

- 任意事件 A 是相应样本空间的一个子集.
- 由样本空间 Ω 中的单个元素组成的子集称为**基本事件**. 而样本空间 Ω 最大的子集 (即 Ω 本身) 称为**必然事件**. 样本空间 Ω 的最小子集 (即空集 $\emptyset$) 称为**不可能事件**.
- 当子集 A 中某个样本点出现了, 就说明事件 A 发生了, 或者说事件 A 发生当且仅当 A 中某个样本点出现了.

■ 事件的关系: 包含, 互不相容, 对立

■ 事件的运算: 交, 并, 补, 差

■ 事件的运算定律: 交换, 结合, 分配, 对偶律

■ 概率测度的公理化介绍:

主观概率 (可信程度), 客观概率 (频率极限), 公理化概率

概率的公理化定义: 设 $\mathcal{A}$ 为样本空间 Ω 上的事件域, $\forall A \in \mathcal{A}$, 若存在实数 $\mathbb{P}(A)$ 与之对应, 且满足

1. 非负性: $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{A}$
2. 正则性: $\mathbb{P}(\Omega) = 1$
3. 可列可加性: 对两两不相容的事件列 $\{A_k\}_{k=1}^{\infty}$ 有

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mathbb{P}(A_k)$$

则称 $\mathbb{P}(A)$ 为事件 A 的概率, 称 $\{\Omega, \mathcal{A}, \mathbb{P}\}$ 为概率空间.

■ 概率的性质:

1. $\mathbb{P}(\emptyset) = 0$;
2. 有限可加性: 对两两不相容的事件列 $\{A_k\}_{k=1}^n$ 有

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k);$$

3. 单调性: 若 $A \subset B$, 则 $\mathbb{P}(A) \leq \mathbb{P}(B)$;

4. **减法定律:** 若 $B \subset A$, 则 $\mathbb{P}(A - B) = \mathbb{P}(A\bar{B}) = \mathbb{P}(A) - \mathbb{P}(B)$; 若对任意两个事件 C, D , 则有 $\mathbb{P}(C - D) = \mathbb{P}(C\bar{D}) = \mathbb{P}(C) - \mathbb{P}(CD)$;
5. $0 \leq \mathbb{P}(A) \leq 1, \forall A$;
6. $\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A)$;
7. **加法定律:** 对于任何事件 A, B 有:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(AB),$$

对于任意三个事件 A, B, C 有:

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(AB) - \mathbb{P}(AC) - \mathbb{P}(BC) + \mathbb{P}(ABC),$$

对于任意 n 个事件 $\{A_i\}_{i=1}^n$ 有:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i < j \leq n} \mathbb{P}(A_i A_j) + \sum_{1 \leq i < j < k \leq n} \mathbb{P}(A_i A_j A_k) - \cdots + (-1)^{n-1} \mathbb{P}(A_1 \cdots A_n);$$

★**补充性质: 次可加性:**

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i).$$

■ 计数原理 & 排列组合

1. 计数原理

- 加法原理: 做一件事共有 n 类方法, 每类方法下又分别有 $m_1, m_2, \dots, m_n$ 种方法;
- 乘法原理: 做一件事共有 n 个步骤, 每个步骤下又分别有 $m_1, m_2, \dots, m_n$ 种方法.

2. 排列组合

- 排列 (不放回) n 选 $r (\leq n)$: $A_n^k = \frac{n!}{(n-k)!}$, 全排列 $A_n^n = n!$

- 排列 (放回) n 选 r : n^r

- 组合 (不放回) n 选 $r (\leq n)$: $C_n^r = \frac{n!}{r!(n-r)!}$
对于组合数 C_n^r , 有如下性质:

(a) $C_n^r = C_n^{n-r}$

(b) $C_n^r = C_{n-1}^{r-1} + C_{n-1}^r$

(c) $C_n^0 + C_n^1 + \cdots + C_n^n = 2^n$

(d) $C_n^1 + 2C_n^2 + \cdots + nC_n^n = n2^{n-1}$

(e) $\sum_{k=0}^n C_n^k C_{m-n}^{n-k} = C_m^n$, 特别地: 当 $m = 2n$ 时, 有 $\sum_{k=0}^n (C_n^k)^2 = C_{2n}^n$ (★Tip: 可以考虑实际意义)

- 组合 (放回) (仅了解不常见): C_{n+r-1}^r

- 推广形式: 一般地, 把 n 个球随机地分成 r 组 ($n > r$), 要求第 i 组恰有 n_i 个球 ($i = 1, \dots, r$), 共有分法: $\frac{n!}{n_1! n_2! \cdots n_r!}$ (★: 常见于多项分布 (Section 3.2))

■ 古典概型

设随机试验的样本空间为 Ω , 若

1. Ω 只含有限个样本点, 即

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$$

2. 每个样本点的出现是等可能的, 即

$$\mathbb{P}(\omega_1) = \mathbb{P}(\omega_2) = \cdots = \mathbb{P}(\omega_n) = \frac{1}{n}$$

则称该试验为**等可能概型**, 也称为**古典概型**.

对于任意事件 A , 我们有如下公式

$$\mathbb{P}(A) = \frac{A \text{ 的有利样本场合数}}{\text{样本点总个数}} = \frac{k}{n}.$$

■ 几何概型

向平面有界区域 Ω 投掷一个点, 点落在可测量面积的平面区域 A , 那么事件 A 发生的概率是

$$\mathbb{P}(A) = \frac{A \text{ 的面积}}{\Omega \text{ 的面积}}$$

则称上述试验为**几何概型**. (Tutorial 2 中的 Exercise 2-4)

■ 条件概率

设 A, B 是两个事件, 且 $\mathbb{P}(B) > 0$, 记

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(AB)}{\mathbb{P}(B)}$$

称为在事件 B 发生的条件下事件 A 发生的**条件概率**.

★ 几点注意:

1. $A|B$ 并非是一个事件;
2. 条件概率也是一种概率, 因为他满足概率的三条公理 (非负性, 正则性, 可列可加性);
3. **乘法公式**: $\mathbb{P}(AB) = \mathbb{P}(A|B)\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A)$
(由于该公式是由条件概率推得, 所以 A, B 两个事件的概率均不可为零)
4. **推广的乘法公式**: $\mathbb{P}(A_1 A_2 \cdots A_n) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 A_2) \cdots \mathbb{P}(A_n|A_1 A_2 \cdots A_{n-1})$
(当然 $\mathbb{P}(A_1 A_2 \cdots A_{n-1}) > 0$)
5. ★ **全概率公式** (涉及到分划的定义): 首先对样本全空间 Ω 有一个分划, 记为 $\{B_i\}_{i=1}^n$, $\{B_i\}$ 满足两个条件: 两两互不相容以及所有事件 $\{B_i\}$ 的并为全空间 Ω ; 那么对于任意事件 A ,

$$\begin{aligned} \mathbb{P}(A) &= \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(A \cap \left(\bigcup_{i=1}^n B_i\right)\right) \\ &= \mathbb{P}\left(\bigcup_{i=1}^n AB_i\right) = \sum_{i=1}^n \mathbb{P}(AB_i) \\ &= \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i) \end{aligned}$$

6. ★ **贝叶斯公式** (接上面全概率公式的设定)

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(AB_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)}$$

7. 了解先验概率, 后验概率的定义 (见 Fig.1)

■ 独立性

1. **定义**: 如果对于任意两个事件 A, B , 有 $\mathbb{P}(AB) = \mathbb{P}(A)\mathbb{P}(B)$, 则称事件 A 与 B 相互独立.

★ 等号左侧是关于两事件的交

贝叶斯 (Bayes) 公式

假设 $B_1, \dots, B_n$ 为样本空间 Ω 的一个分划. 则

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} = \frac{P(A | B_i)P(B_i)}{P(A)}$$

讨论

- $B_1, B_2, \dots, B_n$ 为**原因**. $P(B_i), i = 1, 2, \dots, n$ 为**先验概率**.
- A 为结果, $P(B_i | A)$ 为**后验概率**, 即“由果及因”.
- Bayes 方法广泛应用于网络、分类、诊断、估计、检验、判别、推理等方面.

Figure 1: 先验概率, 后验概率

2. **性质:** 若事件 A 与 B 独立, 则 A 与 $\bar{B}$ 独立, $\bar{A}$ 与 B 独立, $\bar{A}$ 与 $\bar{B}$ 独立.
3. **多个事件的独立性:** 设有 n 个事件 $A_1, A_2, \dots, A_n$, 对任意的 $1 \leq i < j < k < \dots \leq n$, 如果以下等式均成立

$$\begin{cases} \mathbb{P}(A_i A_j) = \mathbb{P}(A_i) \mathbb{P}(A_j), \\ \mathbb{P}(A_i A_j A_k) = \mathbb{P}(A_i) \mathbb{P}(A_j) \mathbb{P}(A_k), \\ \dots\dots\dots \\ \mathbb{P}(A_1 A_2 \dots A_n) = \mathbb{P}(A_1) \mathbb{P}(A_2) \dots \mathbb{P}(A_n), \end{cases}$$

则称这 n 个事件 $A_1, A_2, \dots, A_n$ 相互独立.

★ 两两独立与相互独立不等价, 后者可以推出前者.

4. 两个事件相互独立与互不相容是不等价的.

2 Chapter2: 随机变量

■ 随机变量

1. **定义:** 定义在样本空间 Ω 上的实值函数 $X = X(\omega)$ 称为**随机变量**, 一个随机变量就是一个映射, 从样本空间 Ω 到实数 $\mathbb{R}$.
★ 随机变量 X 是样本点 ω 的一个函数, 这个函数的自变量 (样本点) 可以是数, 也可以不是数, 但因变量一定是实数.
2. **分类:** 离散型随机变量 (随机变量仅可能取有限个或可列个值) 和连续性随机变量 (可能取值充满数轴上的一个区间 (a,b) , 其中 a 可以是 $-\infty$, b 可以是 $+\infty$).
3. **备注 1:** 通常用大写字母 X, Y, Z 等表示随机变量, 其取值用小写字母 x, y, z 等表示 (实数).
4. **备注 2:** 与微积分中的变量不同, 概率论中的随机变量 X 是一种“**随机取值的变量且伴随一个分布**”. 以离散随机变量为例, 我们不仅要知道 X 可能取哪些值, 而且还要知道它取这些值的概率各是多少, 这就需要分布的概念.

■ **随机变量的分布函数或累积分布函数 (CDF)** 我们对离散型随机变量和非离散型随机变量统一地定义了累积分布函数 (CDF) 或分布函数. 随机变量 X 是样本点 ω 的一个实值函数, 若 B 是某些实数组成的集合, 即 $B \subset \mathbb{R}$, $\mathbb{R}$ 表示实数集, 则 $\{X \in B\}$ 表示如下的随机事件

$$\{\omega : X(\omega) \in B\} \subset \Omega.$$

特别, 用等号或不等号把随机变量 X 与某些实数连接起来, 用来表示事件. 如 $\{X \leq a\}$, $\{X > b\}$ 和 $\{a < X < b\}$ 都是随机事件. 具体有

- 记 X 表示掷一颗骰子出现的点数, 则 X 的可能取值为 $1, 2, \dots, 6$. 这是一个离散随机变量. 事件 $A = \{\text{“点数小于等于 3”}\}$, 可以表示为 $A = \{\omega : X(\omega) \in \{1, 2, 3\}\} = \{X \leq 3\}$.
- 记 Y 表示一天内到达某商场的顾客数, 则 Y 的可能取值为 $0, 1, 2, \dots, n$, 这也是一个离散随机变量. 事件 $B = \{\text{“至少 1000 位顾客”}\}$, 可以表示为 $B = \{Y \geq 1000\}$.
- 记 T 表示某种电器产品的使用寿命, 则 T 的可能取值充满区间 $[0, \infty)$. 这是一个连续随机变量. 事件 $C = \{\text{“使用寿命在 40 000 至 50 000 小时之间”}\}$, 可以表示为 $C = \{40000 \leq T \leq 50000\}$.

为了掌握 X 的统计规律性, 我们只要掌握 X 取各个值的概率. 由于

$$\{a < X \leq b\} = \{X \leq b\} \cap \{X \leq a\}^c,$$

$$\{X > e\} = \Omega \cap \{X \leq e\}^c,$$

$$\{X \geq d\} = \Omega \cap \{X < d\}^c = \Omega \cap \left\{ \bigcap_{n=1}^{\infty} \{X \leq d + \frac{1}{n}\} \right\}^c,$$

因此只要对任意实数 x , 知道了事件 $\{X \leq x\}$ 的概率就够了, 这个概率具有累积特性, 常用 F 表示. 另外这个概率与 x 有关, 不同的 x , 此累积概率的值也不同, 为此记

$$F(x) = \mathbb{P}(X \leq x),$$

于是 $F(x)$ 对所有 $x \in (-\infty, \infty)$ 都有定义, 因而 $F(x)$ 是定义在 $(-\infty, \infty)$ 上, 取值于 $[0, 1]$ 的一个函数. 这就是我们下面要引入的分布函数.

1. **CDF 的定义:** 设 X 是一个随机变量, 对任意实数 x , 称

$$F(x) = \mathbb{P}(X \leq x)$$

为随机变量 X 的**分布函数 (CDF)**. 且称 X 服从 $F(x)$, 记为 $X \sim F(x)$. 有时也可用 $F_X(x)$ 以表明 X 的分布函数 (把 X 写成 F 的下标).

2. **CDF 的性质:**

- **单调性:** $F(x)$ 是定义在整个实数轴 $(-\infty, \infty)$ 上的单调非减函数;
- **右连续性:** $F(x+0) = F(x)$, 即 $F(x)$ 是右连续的;

- **有界性:** 对任意的 x , 有 $0 \leq F(x) \leq 1$, 且

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, \quad F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1.$$

还可以证明: 如果一个函数满足了以上三条性质, 那么它必定是某个随机变量的分布函数. 从而**这三条基本性质成为判别某个函数是否能成为分布函数的充要条件**.

3. 概率 $\mathbb{P}$ 与 CDF 的关系: 对于任意的实数 a 与 b , 有

$$\mathbb{P}(a < X \leq b) = F(b) - F(a), \quad \mathbb{P}(X = a) = F(a) - F(a - 0),$$

$$\mathbb{P}(X \geq b) = 1 - F(b - 0), \quad \mathbb{P}(X > b) = 1 - F(b),$$

$$\mathbb{P}(X < b) = F(b - 0), \quad \mathbb{P}(a \leq X \leq b) = F(b) - F(a - 0),$$

$$\mathbb{P}(a \leq X \leq b) = F(b - 0) - F(a - 0).$$

特别当 $F(x)$ 在 a, b 处连续时, 有 $F(a - 0) = F(a), F(b - 0) = F(b)$.

■ 离散型随机变量

1. **概率质量函数 (PMF) 或概率分布列:** 有些随机变量, 它全部可能取到的值是有限个或可列无限多个, 这种随机变量称为离散型随机变量. 要掌握一个离散型随机变量 X 的统计规律, 必须且只需知道 X 的所有可能取值以及取每一个可能值的概率.

- (a) PMF 的定义: 设离散型随机变量 X 所有可能取的值为 $x_k (k = 1, 2, \dots)$, X 取各个可能值的概率, 即事件 $\{X = x_k\}$ 的概率, 为

$$\mathbb{P}(X = x_k) = p(x_k) = p_k, \quad k = 1, 2, \dots$$

可见, X 的统计规律完全由 $\{x_k\}$ 和 $\{p_k\}$ 两个数列决定

- (b) PMF 的性质: 由概率的定义, 可知有如下两条性质

- **非负性:** $p(x_k) \geq 0, \quad k = 1, 2, \dots$
- **正则性:** $\sum_{k=1}^{\infty} p_k = 1$

- (c) PMF 的表示方法:

- 解析式法: $\mathbb{P}\{X = x_k\} = p_k, \quad k = 1, 2, \dots$
- 表格法
- 矩阵法

- (d) 由离散随机变量 X 的分布列很容易写出 X 的分布函数 (图像是阶梯函数, 注意 $\pm\infty$ 处的函数值)

$$F(x) = \sum_{x_k \leq x} p(x_k).$$

但在离散场合, 常用来描述分布的是 PMF, 因为求离散随机变量 X 的有关事件的概率时, 用 PMF 比用 CDF 方便.

2. 几种重要的离散型随机变量

- (a) 单点分布 X : $\mathbb{P}(X = c) = 1, (c = \text{常数});$

★ 以下默认不会退化成单点分布:

- (b) 两点 (0-1) 分布 $X \sim \text{Bernoulli}(p)$: $\mathbb{P}(X = x) = p^x(1-p)^{1-x}, (x = 0, 1), 0 < p < 1;$

- (c) 二项分布 $X \sim \text{Binomial}(n, p)$: $\mathbb{P}(X = k) = C_n^k p^k (1-p)^{n-k}, (k = 0, 1, \dots, n), 0 < p < 1;$

★★ 关于二项分布和伯努利分布的关系:

- 如果 $Y_i \sim_{i.i.d.} \text{Ber}(p)$, 那么 $X = Y_1 + \dots + Y_n \sim \text{Bin}(n, p)$.

- 如果 $X_1 \sim \text{Bin}(n_1, p)$, $X_2 \sim \text{Bin}(n_2, p)$, 同时 X_1 和 X_2 相互独立, 那么 $X = X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$.

(d) 几何分布 $X \sim \text{Geometric}(p)$: $\mathbb{P}(X = k) = (1 - p)^{k-1}p, (k = 1, 2, \dots), 0 < p < 1$;

★★ 关于几何分布和伯努利分布的关系:

- 如果 $Y_i \sim \text{i.i.d. Ber}(p)$, 那么 $X = \inf\{k : Y_k = 1\} \sim \text{Geo}(p)$.
- 无记忆性: $\mathbb{P}(X > n + m | X > n) = \mathbb{P}(X > m)$.

(e) 负二项分布 $X \sim \text{Negative Binomial}(r, p)$: $\mathbb{P}(X = k) = C_{k-1}^{r-1}p^r(1-p)^{k-r}, (k = r, r+1, \dots), 0 < p < 1$;

★★ 关于几何分布和伯努利分布的关系: 如果 $Y_i \sim \text{i.i.d. Ber}(p)$, 那么 $X = \inf\{k : Y_1 + \dots + Y_k = r\} \sim \text{NB}(r, p)$.

(f) 超几何分布 $X \sim \text{Hypergeometric}(r, n, m)$: $\mathbb{P}(X = k) = \frac{C_r^k C_{n-r}^{m-k}}{C_n^m}, (k = 1, 2, \dots, m)$;

(g) 泊松分布 $X \sim \text{Poisson}(\lambda)$: $\mathbb{P}(X = k) = \frac{\lambda^k}{k!}e^{-\lambda}, (k = 0, 1, 2, \dots, \lambda > 0)$.

★★:

- $e^\lambda = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}$;
- 在泊松流中, 记时间间隔 $(0, t]$ 中出现质点数为 X , 则 $X \sim \text{Poisson}(\lambda t)$, 其中 $\lambda > 0$ 是泊松强度.

3. **泊松定理**: 设 $\lambda > 0$ 是一常数, n 为正整数, 在 n 重伯努利试验中, 记事件 A 在一次试验中发生的概率为 p_n (与试验次数 n 有关), 如果有 $\lim_{n \rightarrow \infty} np_n = \lambda$, 则对任一非负整数 k , 有

$$\lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

应用: 对于一个二项分布 $b(n, p)$, 如果 n 足够大, p 足够小而 np 大小合适的话, 可以用泊松分布做近似, 即

$$C_n^k p_n^k (1 - p_n)^{n-k} \approx \frac{(np)^k}{k!} e^{-np}, k = 0, 1, 2, \dots$$

■ 连续型随机变量

1. 概率密度函数 (PDF) 或密度函数:

(a) PDF 的定义: 设随机变量 X 的分布函数为 $F(x)$, 如果存在非负可积函数 $f(x) (-\infty < x < +\infty)$, 使对任意实数有

$$F(x) = \int_{-\infty}^x f(u) du,$$

则称 X 为连续型随机变量, 称 $f(x)$ 为 X 的概率密度函数, 简称密度函数. 连续型随机变量的分布函数是处处连续的.

(b) PDF 的性质:

- $f(x) \geq 0$;
- $\int_{-\infty}^{+\infty} f(x) dx = 1$ 以上两条是密度函数的充要条件;
- $\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$;
- 如 $f(x)$ 在点 x 处连续, 则 $F'(x) = f(x)$;
- 若 X 是连续型随机变量, 则对任意实数 a , $\mathbb{P}(X = a) = 0$. 由于在 $f(x)$ 的连续点 x 处, 有 $f(x)\Delta x \approx \int_x^{x+\Delta} f(u) du = F(x + \Delta x) - F(x)$, 所以

$$f(x) \approx \frac{F(x + \Delta x) - F(x)}{\Delta x}.$$

此比值可以解释为在点 x 附近长 Δx 的区间 $(x, x + \Delta x)$ 内, 单位长所占有的概率. 令 $\Delta x \rightarrow 0$, 则这个比的极限, 即 $F'(x)$ 等于 $f(x)$, 也就是在 x 点处单位长所占有的概率, 或者说它反映了概率在 x 点处的“密集程度”. 从这个意义上讲, 密度函数与离散型的概率分布有类似的概率含义.

2. 几种重要的连续型随机变量

(a) 正态分布 $X \sim N(\mu, \sigma^2)$: $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $-\infty < x < +\infty$, ($\mu \in \mathbb{R}, \sigma > 0$)

★★ 正态分布的相关性质

- i. $f(\mu + x) = f(\mu - x)$, 即是说 $f(x)$ 关于 $x = \mu$ 轴对称;
- ii. μ 是位置参数, σ 是刻度参数, 对于 μ 和 σ 的变化情况有以下几条:

- ▶ μ 由小变大: 图形向右平移, 形状不变;
- ▶ μ 由大变小: 图形向左平移, 形状不变;
- ▶ σ 由小变大, 图形变平坦;
- ▶ σ 由大变小, 图形变尖锐.

- iii. 对于 $\mu = 0, \sigma = 1$ 这种情况, $Y \sim N(0, 1)$ 称为标准正态分布

同时, 我们可以假设 $X = \sigma Y + \mu$, 那么有 $X \sim N(\mu, \sigma^2)$ (正态分布对线性变换具有封闭性)

$$f_Y(y) \triangleq \varphi(y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}, \quad -\infty < y < +\infty;$$

$$F_Y(y) \triangleq \Phi(y) = \int_{-\infty}^y \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \text{ (可以通过查表获取概率值或者是某分位点值)}^1$$

- iv. **Tip:** 若 $X \sim N(\mu, \sigma^2), Y \sim N(0, 1)$, 那么对于概率有以下几条:

$$\text{▶ } \mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \mathbb{P}(Y \leq \frac{x-\mu}{\sigma}) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

$$\text{▶ } \mathbb{P}(Y \leq -x) \stackrel{\text{symmetry}}{=} \mathbb{P}(Y \geq x) = 1 - \mathbb{P}(Y \leq x) \implies \Phi(-x) = 1 - \Phi(x)$$

$$\text{▶ } \mathbb{P}(-x \leq Y \leq x) = \mathbb{P}(Y \leq x) - \mathbb{P}(Y < -x) = 2\Phi(x) - 1, \quad \text{假设 } x > 0$$

- ▶ 对于最后两条, 如果有随机变量 $Z \sim N(0, \sigma^2)$, 黄色部分的性质对 Z 依然适用.

- v. 3σ 原则:

$$\mathbb{P}(-\sigma < X - \mu < \sigma) \approx 0.6826$$

$$\mathbb{P}(-2\sigma < X - \mu < 2\sigma) \approx 0.9544$$

$$\mathbb{P}(-3\sigma < X - \mu < 3\sigma) \approx 0.9974$$

(b) 均匀分布 $X \sim U(a, b)$: $f(x) = \frac{1}{b-a}$, for $a < x < b$;

★★ 均匀分布的相关性质: “均匀分布的等可能性” 对于 $\forall(c, c+L) \subset (a, b)$, 有 $\mathbb{P}(c < X < c+L) = \frac{L}{b-a}$.

(c) 指数分布 $X \sim \text{Exp}(\lambda)$: $f(x) = \lambda e^{-\lambda x}$, for $x > 0$;

★★ 指数分布的相关性质

- Recall: 在 $(0, t]$ 中出现的质点数服从参数为 λt 的泊松分布, 其中 λ 称为泊松强度, 那么第一个质点出现的时间 T 服从指数分布 $\text{Exp}(\lambda)$;
- 指数分布的“无记忆性”: 设 $X \sim \text{Exp}(\lambda)$, 则 $\mathbb{P}(X > s + t | X > s) = \mathbb{P}(X > t)$.

即已知寿命长于 s 的情况下, 再活时间 t 的概率与 s 无关

(d) Γ 分布 $X \sim \Gamma(r, \lambda)$: $f(x) = \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x}$, for $x > 0$, $r > 0, \lambda > 0$

★★ Gamma 分布的相关性质

¹ **p -分位数:** 设 $X \sim f(x)$, 若 $\forall 0 < p < 1$, 存在常数 x_p 满足 $\mathbb{P}(X \leq x_p) = \int_{-\infty}^{x_p} f(x) dx = p$, 也即 $F(x_p) = p$, 则称 x_p 为密度函数 $f(x)$ 的 p -分位数.

- Recall: $\Gamma(r) = \int_0^\infty x^{r-1} e^{-x} dx, \quad r > 0$

Recall: r 为自然数时, $\Gamma(r) = (r-1)!$

- 在 $(0, t]$ 中出现的质点数服从参数为 λ 的泊松分布, 其中 λ 称为泊松强度, 第一个质点出现的时间 T 服从指数分布 $Exp(\lambda)$, 那么第 r 个质点出现的时机服从 Gamma 分布;
- $r = 1$ 时, $\Gamma(1, \lambda) = Exp(\lambda)$;
- $X \sim N(0, 1)$, 那么有 $X^2 \sim \Gamma(\frac{1}{2}, \frac{1}{2})$, (因为 $\Gamma(\frac{1}{2}) = \sqrt{\pi}$).

(e) Beta 分布 $X \sim Beta(a, b)$: $f(x) = \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1}$, for $0 < x < 1$

★★ Beta 分布的相关性质

- Recall: $B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} = \int_0^1 x^{a-1} (1-x)^{b-1} dx$
- $a = b = 1$ 时, $B(1, 1) = U(0, 1)$

■ 随机变量的函数

1. 离散型随机变量函数的 PMF: $Y = g(X)$ 的概率分布: 先写出 Y 的可能取值 $y_1, y_2, \dots, y_i, \dots$, 再找出 $\{Y = y_i\}$ 的等价事件 $\{X \in I\}$ 最后利用 $\mathbb{P}(Y = y_i) = \mathbb{P}(X \in I)$ 求解 PMF

这里的 X 可以是离散型随机变量也可能是连续型随机变量.

2. 连续型随机变量函数的 PDF: 注意 $y = g(x)$ 的性质, 如果单调可直接用定理

定理

设随机变量 X 的密度函数为 $f(x)$, 又设 $y = g(x)$ 为严格单调函数 (严格增或严格减), 其反函数 $h(y) = g^{-1}(y)$ 连续可导. 则 $Y = g(X)$ 的密度函数为

$$f_Y(y) = \begin{cases} |h'(y)| \cdot f(h(y)), & h(y) \text{ 有意义} \\ 0, & \text{其它.} \end{cases}$$

一般方法:

- 确定 y 的范围;
- 根据 CDF 的定义写出 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X \in [h_1(y), h_2(y)])$, 范围 $[h_1(y), h_2(y)]$ 是通过 $g(x) \leq y$ 的函数图看出来的, $h_1(y), h_2(y)$ 有可能是常数或 $\pm\infty$;
- 对 CDF 求导得到 PDF (一定要知道怎么对积分上下限求导).

写完之后注意 pdf 自身的限制!

3. 利用均匀分布生成其他分布:

让 $Z = F_X(X)$, 那么 $Z \sim U(0, 1)$;

让 $U \sim U(0, 1)$, $X = F^{-1}(U)$, 那么 X 的分布函数是 $F(x)$

3 Chapter3: 联合分布

■ **联合分布函数**: 称 $F(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 为随机向量 (X, Y) 的分布函数, 或称为随机变量 X 和 Y 的联合分布函数. 联合分布函数有以下性质:

1. **单调性**: $F(x, y)$ 分别对 x 和 y 是单调不减的, 即当 $x_1 < x_2$ 时, $F(x_1, y) \leq F(x_2, y)$, 对 $\forall y$. 当 $y_1 < y_2$ 时, $F(x, y_1) \leq F(x, y_2)$, 对 $\forall x$;
2. **0-1 值**: $0 \leq F(x, y) \leq 1$, $F(-\infty, y) = 0$, $F(x, -\infty) = 0$, $F(+\infty, +\infty) = 1$;
3. **右连续性**: $F(x, y)$ 对每个变量右连续, 即 $F(x+0, y) = F(x, y)$, $F(x, y+0) = F(x, y)$;
4. 对任意 $x_1 < x_2, y_1 < y_2$ 有:

$$\mathbb{P}(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) \geq 0$$

■ 二维离散随机变量

1. 联合频率函数:

定义: (X, Y) 的联合概率分布为 $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}$, $i, j = 1, 2, \dots$,

性质: 非负性, 正则性

2. 边际频率函数:

定义: 称 $\mathbb{P}(X = x_i) = \sum_{j=1}^{+\infty} p_{ij} = p_{i\cdot}$, $i = 1, 2, \dots$ 为 (X, Y) 关于 X 的边际频率函数;

$\mathbb{P}(Y = y_j) = \sum_{i=1}^{+\infty} p_{ij} = p_{\cdot j}$, $j = 1, 2, \dots$ 为 (X, Y) 关于 Y 的边际频率函数.

★ 对于以上两个函数最后请用表格的形式呈现出来.

3. 多项分布:

定义

假设进行 n 次独立试验, 每次试验有 r 种可能的结果, 各自出现的概率是 $p_1, \dots, p_r$. 令 N_i 是 n 次试验中出现第 i 种试验结果的所有次数, 其中 $i = 1, \dots, r$. 则 $N_1, \dots, N_r$ 的联合频率函数是

$$p(n_1, \dots, n_r) = \binom{n}{n_1 \dots n_r} p_1^{n_1} p_2^{n_2} \cdots p_r^{n_r},$$

称为**多项分布**.

两种计算 N_i 边际频率函数的方法

- 将联合频率函数关于其它的 n_j 求和;
- N_i 可解释为 n 次试验中**成功的次数**, 故 $N_i \sim \text{Bin}(n, p_i)$, 因此

$$p_{N_i}(n_i) = \binom{n}{n_i} p_i^{n_i} (1 - p_i)^{n - n_i}.$$

■ 二维连续随机变量

1. 联合概率密度函数:

定义: 如果二维随机变量 (X, Y) 的分布函数 $F(x, y)$, 存在非负函数 $f(x, y)$, 使得对于任意实数 x, y 有

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du,$$

则称 (X, Y) 是二维连续型随机变量, 函数 $f(x, y)$ 称为 (X, Y) 的概率密度函数或 X 与 Y 的联合概率密度函数.

性质:

(a) 非负性: $f(x, y) \geq 0$

(b) 规范性: $\iint_{\mathbb{R}^2} f(x, y) = F(+\infty, +\infty) = 1$

(c) 如 $f(x, y)$ 在点 (x, y) 连续, 则有 $\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$

(d) $\mathbb{P}\{(X, Y) \in D\} = \iint_{(x, y) \in D} f(x, y) dx dy$, 其中 D 为 XOY 平面上的一个区域.

2. 边际分布函数:

设 (X, Y) 的联合分布函数为 $F(x, y)$, 概率密度函数为 $f(x, y)$, 则

$$F_X(x) = \mathbb{P}(X < x) = \mathbb{P}(X < x, Y < +\infty) = \lim_{y \rightarrow +\infty} F(x, y) = F(x, +\infty)$$

$$F_Y(y) = \mathbb{P}(Y < y) = \mathbb{P}(X < +\infty, Y < y) = \lim_{x \rightarrow +\infty} F(x, y) = F(+\infty, y)$$

分别为 (X, Y) 关于 X 和 Y 的边际分布函数.

还有如下等式:

$$F_X(x) = \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(u, y) dy \right] du$$

$$F_Y(y) = \int_{-\infty}^y \left[\int_{-\infty}^{+\infty} f(x, v) dx \right] dv$$

3. 边际密度函数:

设二维连续型随机变量 (X, Y) 的联合分布函数为 $F(x, y)$, 概率密度函数为 $f(x, y)$, 则关于 X 的边际密度函数为 $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$, 关于 Y 的边际密度函数为 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$.

已知联合分布可以求得边际密度: $f_X(x) = \frac{d}{dx} (F(x, +\infty))$, $f_Y(y) = \frac{d}{dy} (F(+\infty, y))$

注意: 由边际分布可以构造出无数联合分布.

Q1: 关于联合 CDF, 联合 PDF, 边际 CDF, 边际 PDF, 以及概率 $\mathbb{P}$ 之间的关系怎么相互转换?

Q2: 对于联合分布的 CDF, PDF 以及边际分布的 CDF, PDF, 他们的范围怎么确定?

4. 二维正态分布: 二维正态分布的边际分布也都服从正态分布; 但是两个服从正态分布的随机变量构造出的联合分布不一定服从二维正态分布.

定义

若 X, Y 的联合密度为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right]}$$

则称 (X, Y) 服从参数为 $(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的 **二维正态分布**, 记为 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 其中 $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1, \sigma_2 > 0$, $|\rho| < 1$.

5. 二维均匀分布:

■ 独立随机变量:

1. 事件的独立: $\mathbb{P}(AB) = \mathbb{P}(A)\mathbb{P}(B), \forall A, B \in \mathcal{F}$

随机变量的独立: $\mathbb{P}(X \leq x, Y \leq y) = \mathbb{P}(X \leq x) \cdot \mathbb{P}(Y \leq y) \iff F(x, y) = F_X(x) \cdot F_Y(y), \forall x, y \in \mathbb{R}$

若有 X, Y 相互独立, 那么取值也是相互独立的: $\forall x_1 < x_2, y_1 < y_2$,

$$\mathbb{P}(x_1 < X \leq x_2, y_1 < Y \leq y_2) = \mathbb{P}(x_1 < X \leq x_2) \cdot \mathbb{P}(y_1 < Y \leq y_2)$$

2. 二维离散型随机变量

定义: $p_{ij} = p_{i \cdot} \cdot p_{\cdot j}, \forall i, j$

定义

设有界区域 G 的面积为 A . 若随机变量 (X, Y) 的联合密度函数为

$$f(x, y) = \begin{cases} \frac{1}{A}, & (x, y) \in G, \\ 0, & \text{其它}. \end{cases}$$

则称 (X, Y) 服从区域 G 上的**均匀分布**, 记作 $(X, Y) \sim U(G)$.

3. 二维连续型随机变量

定义: $f(x, y) = f_X(x)f_Y(y), \forall$ 连续点 (x, y)

可见: 二维随机变量相互独立, 则边缘分布完全确定联合分布.

4. 二维正态分布的独立性

设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则 (X, Y) 相互独立 $\iff \rho = 0$.

Q: 关于独立性有哪些证明方法?

■ 条件分布:

1. 事件的条件分布概率: $\mathbb{P}(A|B) = \frac{\mathbb{P}(AB)}{\mathbb{P}(B)}, (\mathbb{P}(B) > 0), \forall A, B \in \mathcal{F}$

随机变量的条件分布: 设 (X, Y) 为二维 r.v.s, $\forall y \in \mathbb{R}$ 考虑条件概率 $\mathbb{P}(X \leq x | Y = y), x \in \mathbb{R}$, 这可以视为在 $\{Y = y\}$ 发生的条件下 X 的概率分布 (条件概率).

2. 二维离散型随机变量

定义: 设 (X, Y) 的频率函数为 $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}, (i, j = 1, 2, \dots)$, 考虑在 $\{Y = y_j\}, j = 1, 2, \dots$ 发生的条件下, $\{X = x_i\}$ 发生的条件概率

$$\mathbb{P}(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{\cdot j}}, \quad i = 1, 2, \dots;$$

同理在 $\{X = x_i\}, i = 1, 2, \dots$ 已经发生的条件下, $\{Y = y_j\}$ 发生的条件概率

$$\mathbb{P}(Y = y_j | X = x_i) = \frac{p_{ij}}{p_{i \cdot}}, \quad j = 1, 2, \dots$$

性质: 非负性, 正则性.

3. 二维连续型随机变量

条件密度函数, 条件分布函数: 设 (X, Y) 的概率密度函数为 $f(x, y)$, 若对于固定的 y , 关于 Y 的边际密度 $f_Y(y) > 0$, 则称

$$\frac{f(x, y)}{f_Y(y)} \triangleq f_{X|Y}(x|y), -\infty < x < \infty$$

为在 $\{Y = y\}$ 的条件下, X 的条件密度; 称

$$F_{X|Y}(x|y) \triangleq \int_{-\infty}^x f_{X|Y}(u|y) du, -\infty < x < \infty$$

为在 $\{Y = y\}$ 的条件下, X 的条件分布函数.

类似地, 可以有

$$\frac{f(x, y)}{f_X(x)} \triangleq f_{Y|X}(y|x), -\infty < y < \infty$$

$$F_{Y|X}(y|x) \triangleq \int_{-\infty}^y f_{Y|X}(v|x) dv, -\infty < y < \infty$$

条件密度的性质: 非负性, 正则性

条件密度函数和边际密度函数的关系: $f(x, y) = f_{Y|X}(y|x) \cdot f_X(x)$ 接着就可以有:

$$f_Y(y) = \int_{\mathbb{R}} f(x, y) dx = \int_{\mathbb{R}} f_{Y|X}(y|x) \cdot f_X(x) dx$$

随机变量独立性和条件密度的关系:

$$\begin{aligned} X \text{ 和 } Y \text{ 相互独立} &\iff f(x, y) = f_X(x)f_Y(y) \\ &\iff f_{X|Y}(x|y) = f_X(x) \\ &\quad f_{Y|X}(y|x) = f_Y(y) \end{aligned}$$

4. 均匀分布见 section3.5 课后作业补充题 1.

5. 正态分布

$$\begin{aligned} f_{Y|X}(y|x) &= \frac{1}{\sigma_2 \sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{1}{2} \frac{\left[y - \mu_2 - \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1)\right]^2}{\sigma_2^2(1-\rho^2)}\right) \\ &\sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1-\rho^2)\right). \end{aligned}$$

Q: 条件分布的变量范围应该怎么写?

■ 联合分布随机变量函数:

1. 离散型随机变量函数的概率分布: 设 (X, Y) 的联合分布律为 $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}$ ($i, j = 1, 2, \dots$), 则 $Z = g(X, Y)$ 也是离散型随机变量, 且 Z 的分布律为

$$\mathbb{P}(Z = z_k) = \mathbb{P}(g(X, Y) = z_k) = \sum_{g(x_i, y_j) = z_k} p_{ij}$$

2. 连续型随机变量函数的概率分布: 设二维连续型随机变量 (X, Y) 的联合密度函数为 $f(x, y)$, 则 $Z = g(X, Y)$ 是随机变量, 且 Z 的分布函数为

$$F_Z(z) = \mathbb{P}(Z \leq z) = \mathbb{P}(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy.$$

若 Z 为连续型随机变量, 则它的密度函数为 $f_Z(z) = F'_Z(z)$.

值得注意的是以下几个特例: 设 (X, Y) 是二维连续型随机变量, 它具有概率密度 $f(x, y)$.

(a) $Z = X + Y$ 仍为连续型随机变量, 其概率密度为

$$\begin{aligned} f_Z(z) &\stackrel{\text{general}}{=} \int_{-\infty}^{\infty} f(z - y, y) dy = \int_{-\infty}^{\infty} f(x, z - x) dx \\ &\stackrel{\text{Indep.}}{=} \int_{-\infty}^{\infty} f_X(z - y) f_Y(y) dy = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx \end{aligned}$$

特别地, 以下几个分布具有可加性:(证明见:Appendix A)

► 如果 $X \sim P(\lambda_1), Y \sim P(\lambda_2)$, 同时两随机变量独立, 那么有 $X + Y \sim P(\lambda_1 + \lambda_2)$;

► 如果 $X \sim b(n, p), Y \sim b(m, p)$, 同时两变量独立, 那么有 $X + Y \sim b(n + m, p)$

► 如果 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 同时两变量独立, 那么有 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

推广到一般情形: 对于 $X_i \sim N(\mu_i, \sigma_i^2), i = 1, 2, \dots, n$, 且相互独立, 那么就有 $a_1 X_1 + \dots + a_n X_n \sim N(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2)$.

► 如果 $X \sim \text{Ga}(\alpha_1, \lambda), Y \sim \text{Ga}(\alpha_2, \lambda)$, 同时两变量独立, 那么有 $X + Y \sim \text{Ga}(\alpha_1 + \alpha_2, \lambda)$

推广到指数分布的一般情形: 由于我们有 $\text{Exp}(\lambda) = \text{Ga}(1, \lambda)$, 对于 n 个独立同分布的指数变量 $X_i, i = 1, 2, \dots$ 之和为伽马分布: $\sum_{i=1}^n X_i \sim \text{Ga}(n, \lambda)$.

(b) $Z = \frac{Y}{X}, Z = XY$ 仍为连续型随机变量, 其概率密度分别为

$$\begin{aligned} f_{Y/X}(z) &= \int_{-\infty}^{\infty} |x| f(x, xz) dx = \int_{-\infty}^{\infty} |y| f(yz, y) dy, \\ f_{XY}(z) &= \int_{-\infty}^{\infty} \frac{1}{|x|} f(x, \frac{z}{x}) dx = \int_{-\infty}^{\infty} \frac{1}{|y|} f(\frac{z}{y}, y) dy. \end{aligned}$$

3. 随机向量的变换: 设随机向量 (X, Y) 的联合密度函数为 $p(x, y)$, 函数

$$u = f(x, y), v = g(x, y)$$

有连续偏导数, 且存在唯一的反函数

$$x = x(u, v), y = y(u, v),$$

若 $U = f(X, Y), V = g(X, Y)$, 则 (U, V) 的联合密度函数为

$$q(u, v) = \begin{cases} p(x(u, v), y(u, v))|J|, & \text{若 } (u, v) \text{ 属于 } f, g \text{ 的值域,} \\ 0, & \text{其他,} \end{cases}$$

其中 J 为坐标变换的雅可比行列式

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \left(\frac{\partial(u, v)}{\partial(x, y)} \right)^{-1} = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} \neq 0$$

■ 极值和顺序统计量:

1. 极值统计量: 设 X, Y 是两个相互独立的随机变量, 它们的分布函数分别为 $F_X(x)$ 和 $F_Y(y)$. 现在来求 $M = \max\{X, Y\}$ 及 $N = \min\{X, Y\}$ 的分布函数. 由于 $M = \max\{X, Y\}$ 不大于 z 等价于 X 和 Y 都不大于 z , 故有

$$\mathbb{P}(M \leq z) = \mathbb{P}(X \leq z, Y \leq z).$$

又由于 X 和 Y 相互独立, 得到 $M = \max\{X, Y\}$ 的分布函数为

$$F_M(z) = \mathbb{P}(X \leq z)\mathbb{P}(Y \leq z) = F_X(z)F_Y(z).$$

类似地, 可得 $N = \min\{X, Y\}$ 的分布函数为

$$\begin{aligned} F_N(z) &= \mathbb{P}(N \leq z) = 1 - \mathbb{P}(N > z) \\ &= 1 - \mathbb{P}(X > z, Y > z) = 1 - \mathbb{P}(X > z)\mathbb{P}(Y > z) \\ &= 1 - [1 - F_X(z)][1 - F_Y(z)] \end{aligned}$$

即以上结果容易推广到 n 个相互独立的随机变量的情况. 设 $X_1, X_2, \dots, X_n$ 是 n 个相互独立的随机变量. 它们的分布函数分别为 $F_{X_i}(x_i) (i = 1, 2, \dots, n)$, 则 $M = \max\{X_1, X_2, \dots, X_n\}$ 及 $N = \min\{X_1, X_2, \dots, X_n\}$ 的分布函数分别为

$$F_M(z) = F_{X_1}(z)F_{X_2}(z) \cdots F_{X_n}(z),$$

$$F_N(z) = 1 - [1 - F_{X_1}(z)][1 - F_{X_2}(z)] \cdots [1 - F_{X_n}(z)].$$

特别, 当 $X_1, X_2, \dots, X_n$ 相互独立且具有相同分布函数 $F(x)$ 时有

$$F_M(z) = [F(z)]^n,$$

$$F_N(z) = 1 - [1 - F(z)]^n.$$

2. 顺序统计量: 设 $X_1, X_2, \dots, X_n \sim f(x)$ 是独立同分布的连续型随机变量. $F(x)$ 为对应的分布函数. 将 $X_1, X_2, \dots, X_n$ 由小到大排列为 $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$. 那么对于 $X_{(i)}$ 的密度函数为:

$$f_i(x_i) = \frac{n!}{(i-1)!(n-i)!} [F(x_i)]^{i-1} [1 - F(x_i)]^{n-i} f(x_i).$$

对于两个次序统计量 $(X_{(i)}, X_{(j)}), i < j$ 的联合密度函数为:

$$f_{ij}(x_i, x_j) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(x_i)]^{i-1} [F(x_j) - F(x_i)]^{j-i-1} [1 - F(x_j)]^{n-j} f(x_i)f(x_j), x_i \leq x_j.$$

► 设 $U_i \sim U[0, 1]$ 相互独立, 则 $U_{(k)}$ 的密度为 $f_k(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} [1-x]^{n-k} \sim \text{Beta}(k, n-k+1)$

► $(X_{(1)}, X_{(n)})$ 的联合密度为 $f_{1n}(x_1, x_n) = n(n-1)[F(x_n) - F(x_1)]^{n-2} f(x_1)f(x_n), x_1 \leq x_n$.

Q: 请证明: 独立指数分布变量的最小值仍服从指数分布. 即若 $X_1, X_2, \dots, X_n$ 相互独立, 且皆服从指数分布, 参数分别为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则 $Y = \min(X_1, X_2, \dots, X_n)$ 仍服从指数分布. 求一下这个指数分布的参数.

4 Chapter4: 随机变量的数字特征

■ 随机变量的期望:

1. 离散型随机变量的数学期望: 如果对于离散型随机变量 $X \sim p_k$, 其中 $p_k = \mathbb{P}(X = x_k)$, 如果级数 $\sum_{k=1}^{\infty} |x_k|p_k < \infty$, 那么有:

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} x_k p_k$$

2. 连续型随机变量的数学期望: 如果对于连续型随机变量 $X \sim f(x)$, 如果 $\int_{-\infty}^{\infty} |x|f(x)dx < \infty$, 那么有:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx$$

3. 随机变量函数的数学期望: 设 $y = g(x)$ 为一 (可测) 函数, 则

- (a) 若 X 为离散型, 且频率函数为 $\mathbb{P}(X = x_k) = p_k, k = 1, 2, \dots$, 且 $\sum_{k=1}^{\infty} |g(x_k)|p_k < \infty$, 则

$$\mathbb{E}[Y] = \mathbb{E}[g(X)] = \sum_{k=1}^{\infty} g(x_k)p_k$$

- (b) 若 X 为连续型, 且密度函数为 $f(x)$, 且 $\int_{-\infty}^{\infty} |g(x)|f(x)dx < \infty$, 则

$$\mathbb{E}[Y] = \mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx.$$

4. 二元随机变量函数的数学期望: 设 $z = g(x, y)$ 为二元 (可测) 函数,

- (a) 若 X, Y 为离散型, 且联合频率函数为 $\mathbb{P}(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots$, 若 $\sum_{i,j=1}^{\infty} |g(x_i, y_j)|p_{ij} < \infty$, 则

$$\mathbb{E}[Z] = \mathbb{E}[g(X, Y)] = \sum_{i,j=1}^{\infty} g(x_i, y_j)p_{ij}.$$

- (b) 若 X, Y 为连续型, 且联合密度函数为 $f(x, y)$. 若 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} |g(x, y)|f(x, y)dxdy < \infty$, 则

$$\mathbb{E}[Z] = \mathbb{E}[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y)f(x, y)dxdy.$$

5. 数学期望的基本性质:

- (a) 若 $a \leq X \leq b$, 则 $a \leq \mathbb{E}[X] \leq b$;

- (b) 若 $X \stackrel{a.e.}{=} c$, 则 $\mathbb{E}[X] = c$;

- (c) 设 c 为常数, 则 $\mathbb{E}[cX] = c\mathbb{E}[X]$;

- (d) 设 X, Y 为随机变量, $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$;

- (e) 设 $a_1, \dots, a_n$ 为常数, 则对随机变量 $X_1, \dots, X_n$, 有 $\mathbb{E}[\sum_{i=1}^n a_i X_i] = \sum_{i=1}^n a_i \mathbb{E}[X_i]$;

- (f) 设 X, Y 相互独立, 则 $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$;
若 X, Y 不相关, 也会有 $\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$;

- (g) 设 $X_1, X_2, \dots, X_n$ 相互独立, 则 $\mathbb{E}[X_1 X_2 \cdots X_n] = \mathbb{E}[X_1] \mathbb{E}[X_2] \cdots \mathbb{E}[X_n]$.

6. Markov 不等式: 设随机变量 X 满足 $\mathbb{P}(X \geq 0) = 1$, 且 $\mathbb{E}[X]$ 存在, 则

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X]}{t}$$

■ 方差和标准差:

1. 定义: 对随机变量 X , 若

$$\text{Var}(X) = D(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$$

存在, 则称 $D(X)$ 为随机变量 X 的方差, $\sqrt{D(X)}$ 称为标准差.

★ 视 $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2]$ 为 $g(X) = (X - \mathbb{E}X)^2$ 的数学期望, 则有

(a) 离散型: 设 X 的频率函数为 $\mathbb{P}(X = x_k) = p_k, k = 1, 2, \dots$, 则

$$\text{Var}(X) = \sum_{k=1}^{\infty} (x_k - \mathbb{E}X)^2 \cdot p_k$$

(b) 连续型: 设 X 的概率密度函数为 $f(x)$, 则

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f(x) dx$$

2. 方差的基本性质:

(a) 若 $X \stackrel{\text{a.e.}}{=} c \iff \text{Var}(X) = 0$, 由 Chebyshev 不等式可知 $c = \mathbb{E}X$;

(b) 设 a, b 为常数, 则 $\text{Var}(aX + b) = a^2 \text{Var}(X)$;

(c) 对于随机变量 X 和 Y , 有

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)];$$

特别地, 当 X, Y 独立 (或者不相关) 时,

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y);$$

(d) 对于独立的随机变量 $X_1, X_2, \dots, X_n$, 设 $a_1, \dots, a_n$ 为常数, 那么有

$$\text{Var}\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i).$$

3. Chebyshev 不等式: 设 $\mu = \mathbb{E}X, \sigma^2 = \text{Var}(X)$ 都存在, 则 $\forall \epsilon > 0$, 有

$$\mathbb{P}(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}.$$

常见随机变量的数学期望及方差见 [Appendix B](#).

■ 协方差和相关系数:

1. 协方差的定义: 若 X, Y 的方差均存在, 记

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)],$$

称为 X, Y 的协方差.

2. 协方差的性质:

(a) 若 X, Y 相互独立, 则 $\text{Cov}(X, Y) = 0$;

(b) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;

(c) $\text{Var}(X) = \mathbb{E}(X - \mathbb{E}X)^2 = \text{Cov}(X, X)$;

(d) $\text{Cov}(X, Y) = \mathbb{E}XY - \mathbb{E}X \cdot \mathbb{E}Y$;

(e) $Var(X \pm Y) = Var(X) + Var(Y) \pm 2Cov(X, Y)$.

(f) 对任意 n 个随机变量 $X_1, \dots, X_n$,

$$Var\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n Var(X_i) + 2 \sum_{i=2}^n \sum_{j=1}^{i-1} Cov(X_i, X_j);$$

(g) a 为常数, X 为任意随机变量, $Cov(X, a) = 0$;

(h) 对任意常数 a, b , 有 $Cov(aX, bY) = abCov(X, Y)$;

(i) $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$;

(j) 假设 $U = a + \sum_{i=1}^n b_i X_i$, $V = b + \sum_{j=1}^m d_j Y_j$, 则

$$Cov(U, V) = \sum_{i=1}^n \sum_{j=1}^m b_i d_j Cov(X_i, Y_j).$$

(k) X, Y 相互独立 $\Rightarrow Cov(X, Y) = 0$, 但是一般来说 $Cov(X, Y) = 0 \nRightarrow X, Y$ 独立.

★: E.g. 记 $X \sim N(0, \sigma^2)$, $Y = X^2$, 此时 XY 不独立, 但是 $Cov(X, Y) = 0$.

3. 相关系数的定义: 称

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

为 X, Y 的相关系数.

4. 理解相关性:

(a) 当 $Cov(X, Y) > 0$ 时, 有 $\rho > 0$, 称 X 与 Y **正相关**, 这时两个偏差 $(X - \mathbb{E}X)$ 与 $(Y - \mathbb{E}Y)$ 有同时增加或同时减少的倾向. 由于 $\mathbb{E}X$ 与 $\mathbb{E}Y$ 都是常数, 故等价于 X 与 Y 有同时增加或同时减少的倾向, 这就是正相关的含义.

(b) 当 $Cov(X, Y) < 0$ 时, 有 $\rho < 0$, 称 X 与 Y **负相关**, 这时有 X 增加而 Y 减少的倾向, 或有 Y 增加而 X 减少的倾向, 这就是负相关的含义.

(c) 当 $Cov(X, Y) = 0$ 时, 有 $\rho = 0$, 称 X 与 Y **不相关**. 这时可能由两类情况导致: 一类是 X 与 Y 的取值毫无关联 (即我们说的独立), 另一类是 X 与 Y 间存有某种非线性关系. **一般来说: 独立带来不相关, 但是不相关并非独立.**

5. 相关系数的性质:

(a) $-1 \leq \rho_{XY} \leq 1$;

(b) 二维正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的相关系数就是 ρ . 所以有: $\rho = Cov(X, Y) = 0 \Leftrightarrow X, Y$ 相互独立;

(c) $\rho(X, Y) = \pm 1$ 的充要条件是 X 与 Y 间几乎处处有线性关系, 即存在 $a \neq 0$ 与 b , 使得 $\mathbb{P}(Y = aX + b) = 1$, 其中当 $\rho_{XY} = 1$ 时, 有 $a > 0$ (完全正相关); 当 $\rho_{XY} = -1$ 时, 有 $a < 0$ (完全负相关).

■ 条件期望:

1. 定义: 给定 $X = x$ 的情况下, Y 的条件期望定义为

(a) 离散: $\mathbb{E}[Y|X = x] = \sum_{y \in \mathbb{E}} y p_{Y|X}(y|x)$;

(b) 连续: $\mathbb{E}[Y|X = x] = \int_{\mathbb{R}} y f_{Y|X}(y|x) dy$.

一般函数 $h(Y)$ 的条件期望:

(a) 离散: $\mathbb{E}[h(Y)|X = x] = \sum_{y \in \mathbb{R}} h(y) p_{Y|X}(y|x)$;

(b) 连续: $\mathbb{E}[h(Y)|X = x] = \int_{\mathbb{R}} h(y) f_{Y|X}(y|x) dy$.

2. 理解条件期望: 以 $\mathbb{E}[Y|X]$ 和 $\mathbb{E}[Y|X = x]$ 为例:

- (a) 给定随机变量 X 一个值 x , 此时只有 Y 具有随机性, 若对 $Y|X = x$ 求期望, 是一个关于 x 的数字;
- (b) 但是对 X 没有任何给定值的情况下, $\mathbb{E}[Y|X]$ 是一个关于 X 的随机变量, 可以看成是 X 的某个函数. (可以通过 Chap2 最后一部分的内容, 得到这个新的随机变量的 pdf 或者 pmf)

3. 随机变量的性质:

- (a) $\mathbb{E}[c|X] = c$;
- (b) $\mathbb{E}[aX + bY|Z] = a\mathbb{E}[X|Z] + b\mathbb{E}[Y|Z]$;
- (c) 若 X 与 Y 独立, 则 $\mathbb{E}[Y|X] = \mathbb{E}Y$

4. 两个公式:

- (a) 重期望公式: $\mathbb{E}Y = \mathbb{E}[\mathbb{E}[Y|X]]$;
- (b) 方差分解: $\text{Var}(Y) = \text{Var}(\mathbb{E}[Y|X]) + \mathbb{E}[\text{Var}(Y|X)]$.

5 Chapter5: 大数定律与中心极限定理

■ 依概率收敛:

1. 定义: 设有 ξ 和一系列随机变量 $\xi_1, \xi_2, \dots$, 若对于任意 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| \geq \epsilon) = 0,$$

则称 $\{\xi_n\}$ 依概率收敛于 ξ , 记为 $\xi_n \xrightarrow{\mathbb{P}} \xi$.

2. 理解: $\xi_n \xrightarrow{\mathbb{P}} \xi$ 的直观意义: 随着 n 的增大, 绝对误差 $|\xi_n - \xi|$ 较大的可能性越来越小.

■ 大数定律:

1. 伯努利大数定律: 设 n_A 是 n 次独立重复试验中事件 A 发生的次数, 且 $\mathbb{P}(A) = p$. 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{n_A}{n} - p\right| \geq \epsilon\right) = 0.$$

2. 切比雪夫大数定律: 设 $\{X_n\}$ 为相互独立的随机变量列, 且具有相同的数学期望 μ 和方差 σ^2 . 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \geq \epsilon\right) = 0.$$

3. 理解切比雪夫大数定律: 具有相同数学期望 μ 和方差 σ^2 的独立随机变量序列的算术平均值 $\bar{X} \triangleq \frac{1}{n} \sum_{i=1}^n X_i$ 依概率收敛于数学期望 μ . 因此, 当 n 足够大时, 算术平均值几乎是一常数.

4. 补充两个性质:

- 令 $X_1, X_2, \dots$ 是独立随机变量序列, 具有均值 $\mathbb{E}[X_i] = \mu$ 和方差 $\text{Var}(X_i) = \sigma_i^2$. 如果 $n^{-2} \sum_{i=1}^n \sigma_i^2 \rightarrow 0$, 那么依概率有 $\bar{X} \rightarrow \mu$.
- 令 X_i 如上问, 但是具有 $\mathbb{E}[X_i] = \mu_i$ 和 $n^{-1} \sum_{i=1}^n \mu_i \rightarrow \mu$, 那么依概率也有 $\bar{X} \rightarrow \mu$.

■ 中心极限定理:

中心极限定理就是研究随机变量和的极限分布在什么条件下为正态分布的问题.

1. 定义: 令 $\{X_n\}$ 为独立随机变量列且 $\mathbb{E}[X_n] = \mu_n, \text{Var}(X_n) = \sigma_n^2$. 令 $Z_n = X_1 + \dots + X_n$. 若归一化后的随机变量 $Z_n^* = \frac{Z_n - \mathbb{E}Z_n}{\sqrt{\text{Var}(Z_n)}}$ 的分布函数 $F_n(x)$, 对任意 x 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} \mathbb{P}\left[\frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{\sqrt{\sum_{k=1}^n \sigma_k^2}} \leq x\right] = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x),$$

则称 $\{X_n\}$ 服从**中心极限定理**. 我们也把上式记为 $Z_n^* \Rightarrow \mathcal{N}(0, 1)$.

2. 独立同分布下的 CLT: 设 $\{X_n\}$ 为独立同分布的随机变量列, 其数学期望和方差分别为

$$\mathbb{E}X_k = \mu, \quad \text{Var}(X_k) = \sigma^2 > 0, \quad k = 1, 2, \dots$$

则 $\{X_n\}$ 服从中心极限定理, 即

$$Z_n^* = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \Rightarrow \mathcal{N}(0, 1).$$

3. 二项分布的正态近似: 设 $\{X_n\}$ 为服从参数为 $p, p \in (0, 1)$ 的独立伯努利分布随机函数列, 记 $\eta_n = \sum_{i=1}^n X_i$, 则 $\eta_n \sim B(n, p)$, 对任意的 x , 有

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x).$$

对于二项分布 $X \sim B(n, p)$, 当 n 很大时, $\eta_n \approx \mathcal{N}(np, np(1-p))$, (区别于泊松近似).

A 几个常见卷积公式

A.1 泊松分布的可加性:

例 3.3.2 (泊松分布的可加性) 设随机变量 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$, 且 X 与 Y 独立, 证明 $Z = X + Y \sim P(\lambda_1 + \lambda_2)$.

证明 首先指出, $Z = X + Y$ 可取 $0, 1, 2, \dots$ 所有非负整数. 而事件 $\{Z = k\}$ 是如下诸互不相容事件

$$\{X = i, Y = k - i\}, \quad i = 0, 1, \dots, k$$

的并, 再考虑到独立性, 则对任意非负整数 k , 有

$$P(Z = k) = \sum_{i=0}^k P(X = i)P(Y = k - i). \quad (3.3.1)$$

这个概率等式被称为离散场合下的**卷积公式**. 利用此公式可得

$$\begin{aligned} P(Z = k) &= \sum_{i=0}^k \left(\frac{\lambda_1^i}{i!} e^{-\lambda_1} \right) \left(\frac{\lambda_2^{k-i}}{(k-i)!} e^{-\lambda_2} \right) \\ &= \frac{(\lambda_1 + \lambda_2)^k}{k!} e^{-(\lambda_1 + \lambda_2)} \sum_{i=0}^k \frac{k!}{i!(k-i)!} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2} \right)^i \left(\frac{\lambda_2}{\lambda_1 + \lambda_2} \right)^{k-i} \\ &= \frac{(\lambda_1 + \lambda_2)^k}{k!} e^{-(\lambda_1 + \lambda_2)} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2} + \frac{\lambda_2}{\lambda_1 + \lambda_2} \right)^k \\ &= \frac{(\lambda_1 + \lambda_2)^k}{k!} e^{-(\lambda_1 + \lambda_2)}, \quad k = 0, 1, \dots, \end{aligned}$$

这表明 $X + Y \sim P(\lambda_1 + \lambda_2)$, 结论得证. 注意 $X - Y$ 不服从泊松分布.

A.2 二项分布的可加性:

例 3.3.3(二项分布的可加性) 设随机变量 $X \sim b(n, p)$, $Y \sim b(m, p)$, 且 X 与 Y 独

146

§ 3.3 多维随机变量函数的分布

立, 证明 $Z = X + Y \sim b(n + m, p)$.

证明 首先指出, $Z = X + Y$ 可取 $0, 1, 2, \dots, n + m$ 等 $n + m + 1$ 个不同的值, 利用离散场合的卷积公式(3.3.1), 可把事件 $\{Z = k\}$ 的概率表示为

$$P(Z = k) = \sum_{i=0}^k P(X = i)P(Y = k - i).$$

因为 $X \sim b(n, p)$, $Y \sim b(m, p)$, 所以上式中只需考虑: $i \leq n, k - i \leq m$, 即 $i \leq n, i \geq k - m$.

因此记

$$a = \max\{0, k - m\}, \quad b = \min\{n, k\},$$

则

$$\begin{aligned} P(Z = k) &= \sum_{i=a}^b P(X = i)P(Y = k - i) \\ &= \sum_{i=a}^b \binom{n}{i} p^i (1 - p)^{n-i} \cdot \binom{m}{k-i} p^{k-i} (1 - p)^{m-(k-i)} \\ &= p^k (1 - p)^{n+m-k} \sum_{i=a}^b \binom{n}{i} \binom{m}{k-i}. \end{aligned}$$

利用超几何分布可证明:

$$\sum_{i=a}^b \frac{\binom{n}{i} \binom{m}{k-i}}{\binom{n+m}{k}} = 1 \quad \text{或} \quad \sum_{i=a}^b \binom{n}{i} \binom{m}{k-i} = \binom{n+m}{k}.$$

由此可得

$$P(Z = k) = \binom{n+m}{k} p^k (1 - p)^{n+m-k}, \quad k = 0, 1, \dots, n + m.$$

这表明 $Z = X + Y \sim b(n + m, p)$, 即在参数 p 相同情况下, 二项分布的卷积仍是二项分布,

A.3 正态分布的可加性:

例 3.3.7 (正态分布的可加性) 设随机变量 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 独立, 证明 $Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

证明 首先指出 $Z = X + Y$ 仍在 $(-\infty, \infty)$ 上取值, 利用卷积公式 (3.3.13) 可得

$$p_z(z) = \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2}\left[\frac{(z-y-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\} dy,$$

对上式被积函数中的指数部分按 y 的幂次展开, 再合并同类项, 不难得到

$$\frac{(z-y-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} = A\left(y - \frac{B}{A}\right)^2 + \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2},$$

其中

$$A = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}, \quad B = \frac{z-\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}.$$

代回原式, 可得

$$p_z(z) = \frac{1}{2\pi\sigma_1\sigma_2} \exp\left\{-\frac{1}{2} \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2}\right\} \cdot \int_{-\infty}^{\infty} \exp\left\{-\frac{A}{2}\left(y - \frac{B}{A}\right)^2\right\} dy.$$

利用正态密度函数的正则性, 上式中的积分应为 $\sqrt{2\pi}/\sqrt{A}$, 于是

$$p_z(z) = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left\{-\frac{1}{2} \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2}\right\},$$

这正是均值为 $\mu_1 + \mu_2$, 方差为 $\sigma_1^2 + \sigma_2^2$ 的正态密度函数.

上述结论表明: 两个独立的正态变量之和仍为正态变量, 其分布中的两个参数分别对应相加, 即

$$N(\mu_1, \sigma_1^2) * N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2). \quad (3.3.14)$$

A.4 Gamma 分布的可加性:

例 3.3.8(伽马分布的可加性) 设随机变量 $X \sim Ga(\alpha_1, \lambda)$, $Y \sim Ga(\alpha_2, \lambda)$, 且 X 与 Y 独立, 证明 $Z = X + Y \sim Ga(\alpha_1 + \alpha_2, \lambda)$.

证明 首先指出 $Z = X + Y$ 仍在 $(0, \infty)$ 上取值, 所以当 $z \leq 0$ 时, $p_Z(z) = 0$. 而当 $z > 0$ 时, 可用卷积公式 (3.3.13), 此时被积函数 $p_X(z-y)p_Y(y)$ 的非零区域为 $0 < y < z$, 故

$$\begin{aligned} p_Z(z) &= \frac{\lambda^{\alpha_1 + \alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^z (z-y)^{\alpha_1-1} e^{-\lambda(z-y)} \cdot y^{\alpha_2-1} e^{-\lambda y} dy \\ &= \frac{\lambda^{\alpha_1 + \alpha_2} e^{-\lambda z}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^z (z-y)^{\alpha_1-1} y^{\alpha_2-1} dy \\ &= \frac{\lambda^{\alpha_1 + \alpha_2} e^{-\lambda z}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} z^{\alpha_1 + \alpha_2 - 1} \int_0^1 (1-t)^{\alpha_1-1} t^{\alpha_2-1} dt, \end{aligned}$$

最后的积分是贝塔函数, 它等于 $\Gamma(\alpha_1)\Gamma(\alpha_2)/\Gamma(\alpha_1 + \alpha_2)$. 代入上式得

$$p_Z(z) = \frac{\lambda^{\alpha_1 + \alpha_2}}{\Gamma(\alpha_1 + \alpha_2)} z^{\alpha_1 + \alpha_2 - 1} e^{-\lambda z}.$$

这正是形状参数为 $\alpha_1 + \alpha_2$, 尺度参数仍为 λ 的伽马分布.

这个结论表明: 两个尺度参数相同的独立的伽马变量之和仍为伽马变量, 其尺度参数不变, 而形状参数相加, 即

$$Ga(\alpha_1, \lambda) * Ga(\alpha_2, \lambda) = Ga(\alpha_1 + \alpha_2, \lambda). \quad (3.3.16)$$

显然这个结论可推广到有限个尺度参数相同的独立伽马变量之和上.

另外由第二章中我们知道, 伽马分布有两个常用的特例: 指数分布和卡方分布, 即

$$Exp(\lambda) = Ga(1, \lambda), \quad \chi^2(n) = Ga\left(\frac{n}{2}, \frac{1}{2}\right),$$

由此又可以得到另两个结论:

(1) m 个独立同分布的指数变量之和为伽马变量, 即

$$\underbrace{Exp(\lambda) * Exp(\lambda) * \cdots * Exp(\lambda)}_{m \text{ 个}} = Ga(m, \lambda). \quad (3.3.17)$$

B 常见随机变量的数学期望及方差

离散分布	p.m.f	期望	方差
0-1 分布 $Ber(p)$	$p_k = p^k(1-p)^{1-k}, \quad k = 0, 1$	p	$p(1-p)$
二项分布 $b(n, p)$	$p_k = C_n^k p^k(1-p)^{n-k}, \quad k = 0, 1, \dots, n$	np	$np(1-p)$
泊松分布 $Poi(\lambda)$	$p_k = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$	λ	λ
超几何分布 $h(n, N, M)$	$p_k = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, \quad k = 1, 2, \dots, r$ $r = \min\{M, n\}$	$\frac{nM}{N}$	$\frac{nM(N-M)(N-n)}{N^2(N-1)}$
几何分布 $Ge(p)$	$p_k = (1-p)^{k-1}p, \quad k = 1, 2, \dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
负二项分布 $Nb(r, p)$	$p_k = C_{k-1}^{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
连续分布	p.d.f	期望	方差
正态分布 $N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}, \quad -\infty < x < \infty$	μ	σ^2
均匀分布 $U(a, b)$	$f(x) = \frac{1}{b-a}, \quad a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $Exp(\lambda)$	$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Gamma 分布 $Ga(\alpha, \lambda)$	$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$
Beta 分布 $Be(a, b)$	$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, \quad 0 < x < 1$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$
柯西分布 $Cau(\mu, \lambda)$	$f(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + (x-\mu)^2}, \quad -\infty < x < \infty$	不存在	不存在