



Giralerfics

C5 §1 大数定律

* 依概率收敛

$X, X_1, X_2, \dots, X_n$ 为随机变量, 对 $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|X_n - X| \geq \varepsilon\} = 0$, 则 $X_n \xrightarrow{P} X$.

* 若 $g(\cdot)$ 是连续函数, $X_n \xrightarrow{P} X$, 则 $g(X_n) \xrightarrow{P} g(X)$.

* 附: 切比雪夫不等式: 若有 $E(X) = \mu, D(X) = \sigma^2$.

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2} \quad (\text{或 } P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}).$$

* 几乎处处收敛 $X_n \xrightarrow{a.s.} X \Rightarrow X_n \xrightarrow{P} X$.

* 伯努利大数定律

设 n 为 n 次独立试验中事件 A 发生的次数, 且 $P(A) = p$. 则 $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\frac{nA}{n} - p| \geq \varepsilon\} = 0$.

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 次试验} \\ 0, & \text{第 } i \text{ 次试验} \end{cases}$$

证明:

* 切比雪夫大数定律

设 $\{X_n\}$ 为相互独立的随机变量列, 且 $E(X_i) = \mu, D(X_i) = \sigma^2$. 则 $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n X_i - \mu| \geq \varepsilon\} = 0$.

证明: 记 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \Rightarrow E(\bar{X}_n) = \mu, D(\bar{X}_n) = \frac{\sigma^2}{n}$. 由切比雪夫不等式: $P\{|\bar{X}_n - \mu| \geq \varepsilon\} \leq \frac{\sigma^2/n}{\varepsilon^2} \rightarrow 0 \quad (n \rightarrow \infty)$.

* 辛钦大数定律

设 $\{X_n\}$ 为独立同分布 r.v. 列, $E(X_i) = \mu$ 存在, 则 $\bar{X}_n \xrightarrow{P} \mu$.

* 强大数定律

$$\bar{X}_n \xrightarrow{a.s.} \mu$$

C5 §2 中心极限定理

* $\{X_n\}$ 为 i.i.d. 的 r.v. 列, 有 $E(X_i) = \mu, D(X_i) = \sigma^2$. 标准化 r.v. $Z_n = \frac{(\sum_{i=1}^n X_i - E(\sum_{i=1}^n X_i)) / \sqrt{D(\sum_{i=1}^n X_i)}}{\sqrt{n}}$. 则 Z_n 服从中心极限定理.

$$\text{即有 } \lim_{n \rightarrow \infty} F_n(z) = \int_{-\infty}^z \frac{1}{\sigma \sqrt{n}} e^{-\frac{t^2}{2n\sigma^2}} dt = \Phi(z).$$

* 即 n 足够大时, 有 $\sum_{i=1}^n X_i \stackrel{d}{\sim} N(np, n\sigma^2)$ 或 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \stackrel{d}{\sim} N(\mu, \frac{\sigma^2}{n})$ 也即 $Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \stackrel{d}{\sim} N(0, 1)$.

* 棣莫弗-拉普拉斯中心极限定理

$n \sim b(n, p)$. 则 n 可视为 $X_1 + \dots + X_n, X_i \sim 0-1$ 分布. $\Rightarrow E(X_i) = p, D(X_i) = p(1-p)$.

故 $n \sim \sum_{i=1}^n X_i \stackrel{d}{\sim} N(np, np(1-p))$, 也即 $\frac{n - np}{\sqrt{np(1-p)}} \stackrel{d}{\sim} N(0, 1)$.

* 高尔顿板实验模型

* 需要多少 xxx

*

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 次向右} \\ -1, & \text{第 } i \text{ 次向左} \end{cases}$$

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 次需要 } x_{1i} \\ 0, & \text{第 } i \text{ 次不用 } x_{1i} \end{cases}$$

C6 §2 数理统计基本概念

* 简单随机样本

独立, 与总体同分布.

* 样本的变异性

样本的联合分布: 总体分布的 n 次方.

* 常用统计量

$$\textcircled{1} \text{ 样本均值 } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\textcircled{2} \text{ 样本方差 } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\textcircled{3} \text{ 样本标准差 } S = \sqrt{S^2}$$

$$\textcircled{4} \text{ 样本 } k \text{ 阶矩 } A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, A_1 = \bar{X}$$

$$\textcircled{5} \text{ 样本 } k \text{ 阶中心矩 } B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, B_2 = S^2$$

$$\textcircled{6} \text{ 顺序统计量}$$

$$\textcircled{7} \text{ 极小值 } X_{(1)}$$

$$\textcircled{8} \text{ 极大值 } X_{(n)}$$

* 样本矩的特征

① X_i 独立, 与 X 同分布 $\Rightarrow X_i^k$ 独立, 与 X^k 同分布.

$$\textcircled{2} E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k) = \mu_k \quad (\text{若 } k \text{ 阶矩存在})$$

$$\textcircled{3} A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k \quad (n \rightarrow \infty), \quad g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k) \quad (n \rightarrow \infty)$$

* 样本均值和方差的特征

$$\textcircled{1} E(\bar{X}) = \mu$$


$$\textcircled{2} D(\bar{X}) = \frac{\sigma^2}{n}$$

$$\textcircled{3} E(S^2) = \sigma^2$$

$C_6 S_3$ 抽样分布.

* χ^2 -分布

$X_1, X_2, \dots, X_n$ 来自总体 $N(\mu, 1)$ * 则 $X^2 = X_1^2 + X_2^2 + \dots + X_n^2 \sim \chi^2(n)$



* 可加性: $X_1^2 \sim \chi^2(n_1)$, $X_2^2 \sim \chi^2(n_2)$, 且二者独立 $\Rightarrow X_1^2 + X_2^2 \sim \chi^2(n_1 + n_2)$.

* 数字特征: ① $E(X^2) = n \cdot E(X_1^2) = n \cdot \overline{D(X_1)} + n \cdot \overline{E(X_1)}^2 = n$.

$$\textcircled{2} \mathcal{D}(X^3) = n \cdot \mathcal{D}(X_1^3) = n \cdot E(X_1^4) - n(E(X_1^3))^2 = 3n - n = 2n.$$

$$\rightarrow E(x_i^2) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{x}} e^{-x/2} dx = \frac{1}{\sqrt{x}} \cdot \frac{1}{\sqrt{x}} \int_0^{\infty} \left(\frac{1}{x}\right)^{-1/2} e^{-\frac{1}{2}x} d\left(\frac{1}{x}\right) = \frac{1}{\sqrt{x}} \cdot \frac{1}{\sqrt{x}} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{1}{\sqrt{x}} \cdot \frac{1}{\sqrt{x}} \cdot \sqrt{\pi} = 3$$

* 七-分布.

$X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 独立, 则 $t = \frac{X}{\sqrt{Y/n}} \sim t(n)$.

* 图表: 对称, 近似 $N(0,1)$. $N > 45$ 时可以为 $g(N) = N(0,1)$. 比 $N(0,1)$ 方差大 (平坦).

* 数字特征: $E(t) = 0$, $D(t) = \frac{n}{n-2}$ ($n > 2$).

* F-分布.

$$U \sim \chi^2(n_1), \quad V \sim \chi^2(n_2), \quad \text{且 } U, V \text{ 独立} \Rightarrow F = \frac{U/n_1}{V/n_2} \sim F(n_1, n_2)$$

* 图象: 一个在起, $n_1 \uparrow$, 顶点 $\rightarrow$; $n_2 \uparrow$, 顶点 $\nearrow$.

* 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim \underline{F(n_2, n_1)}$.

* 若 $T \sim t(n)$, 则 $T^2 = \frac{X^2/1}{Y/n} \sim F(1, n)$.

* α -分位点.

$$P\{X \leq x_{\alpha}\} = F_X(x_{\alpha}) = \alpha.$$

* 标准正态: $u_{\alpha} = -u_{1-\alpha}$.

* t 分布: $t_{\alpha}(n) = -t_{1-\alpha}(n)$. 且 $n \rightarrow \infty$ 时 $t_{\alpha}(n) \rightarrow u_{\alpha}$.

* 长方分布: $n \rightarrow \infty$ 时 $f_n^+(x) \rightarrow \frac{1}{x} (1 + \sqrt{2n-1})^{-1}$

* F分布:

三次公式: $F_2(n_1, n_2) = 1 / \underline{F_{1-2}(n_2, n_1)}$.

* 抽样分布定理. 证明略, 但要求.

(一) 样本 $X_1, \dots, X_n$ 来自总体 $X \sim N(\mu, \sigma^2)$, 则 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$.

(二) 样本 $X_1, \dots, X_n$ 来自总体 $X \sim N(\mu, \sigma^2)$ 则有: ① $\bar{X}, S^2$ 相互独立. ② $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

(三) 样本 $X_1, \dots, X_n$ 来自总体 $X \sim N(\mu, \sigma^2)$, 则 $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ ← 用 S 替代未知 σ , 估计 μ .

(四) **定理四** 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu_1, \sigma_1^2)$ 的样本; $Y_1, Y_2, \dots, Y_m$ 是总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的样本, 且两样本相互独立, 两样本均值和样本方差分别为 $\bar{X}, \bar{Y}, S_1^2, S_2^2$. 则

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

证 由定理二, 有

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1), \quad \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1)$$

因两样本独立, 故 S_1^2, S_2^2 独立

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} = \frac{\frac{(n_1 - 1)S_1^2}{\sigma_1^2} / (n_1 - 1)}{\frac{(n_2 - 1)S_2^2}{\sigma_2^2} / (n_2 - 1)} \sim F(n_1 - 1, n_2 - 1)$$

(2) **定理五** 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu, \sigma^2)$ 的样本;
 $Y_1, Y_2, \dots, Y_n$ 是总体 $Y \sim N(\mu_2, \sigma^2)$ 的样本, 且两样本相互独立.
 两样本均值和样本方差分别为 $\bar{X}, \bar{Y}, S_1^2, S_2^2$. 则

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$, $S_w = \sqrt{S_w^2}$.

未知 $\sigma_1^2 = \sigma_2^2 = \sigma^2$,
估计 $\mu_1 - \mu_2$.

C7S1 点估计

* 矩估计

可能不存在。
 用样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 替代总体矩 $\mu_k = E(X^k)$ 。
 矩法矩估计有 $A_k \rightarrow \mu_k$ 。
 做法: 求出 $\mu_1, \dots, \mu_m$ 关于 $\theta_1, \dots, \theta_m$ 的表达式。
 反解得 $\theta_1, \dots, \theta_m$ 关于 $\mu_1, \dots, \mu_m$ 的方程组。
 代入 $\mu_k = A_k$ 得 $\hat{\theta}_1, \dots, \hat{\theta}_m$ 。
 几个未知数到几个方程。
 $\Rightarrow$ 量级同阶。

* 任意 $E(X) = \mu, D(X) = \sigma^2$ 的情形:

$$\begin{cases} \mu_1 = \mu \\ \mu_2 = \sigma^2 + \mu^2 \end{cases} \Rightarrow \begin{cases} \mu = \mu_1 \\ \sigma^2 = \mu_2 - \mu_1^2 \end{cases} \quad \text{代入 } \mu_1 = A_1 = \bar{X}, \mu_2 = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \Rightarrow \begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2 \triangleq S^2 \end{cases}$$

* $X \sim U(a, b)$ 均匀分布。

$$\begin{cases} \hat{a} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \\ \hat{b} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \end{cases}$$

* $X \sim b(m, p)$ 。

$$\mu_1 = mp \Rightarrow p = \frac{\mu_1}{m}, A_1 = \bar{X} \Rightarrow \hat{p} = \frac{\bar{X}}{m}.$$

* $X \sim P(\lambda)$ 。

$$\mu_1 = E(X) = \lambda \Rightarrow \lambda = \mu_1, A_1 = \bar{X} \Rightarrow \hat{\lambda} = \bar{X}.$$

* 求 $P(X=0)$ 的矩估计: $P(X=0) = e^{-\lambda}$, 直接代入 $\lambda = \hat{\lambda} \Rightarrow e^{-\bar{X}}$ 。

非连续 $g(\theta) = g(\hat{\theta})$ 。

* 最大似然估计

(略)。

* 似然函数 $\rightarrow$ 联合密度 $\rightarrow \prod_{i=1}^n f(x_i; \theta)$ 。

* 对数似然方程。

* 求导方法不适用 $\rightarrow$ 定义。eg. $X \sim U(a, b)$, 估计 a, b 。

C7 §2 估计量的评价标准

* 无偏性

* 概念

无偏估计、有偏估计

设总体 $X \sim F(x; \theta)$ ($\theta \in \Theta$), Θ 为参数空间.
 设 $X_1, X_2, \dots, X_n$ 为总体 X 的样本, $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为未知参数 θ 的点估计.
定义 若估计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 的数学期望存在, 且
 $\forall \theta \in \Theta$ 有 $E_{\theta}(\hat{\theta}) = \theta$ (表示利用总体分布 $F(x; \theta)$ 计算, 得出的数学期望与参数 θ 有关)
 则称 $\hat{\theta}$ 为 θ 的 **无偏(unbiased)估计**, 否则称为 **有偏估计**.

偏差 估计量期望减去真值。为零为无偏估计, 不为零为有偏估计。

渐进无偏 偏差在 n 趋于无穷时的极限为 0。

* 实例

任意期望与方差存在的分布 其样本均值和样本方差为期望和方差的无偏估计。

证 由 CH6 §2 的计算结果有 这就是为什么样本方差定义为 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 的原因
 $E(\hat{\mu}) = E(\bar{X}) = \mu$
 $E(\hat{\sigma}^2) = E(S^2) = \sigma^2$
 故 $\hat{\mu} = \bar{X}, \hat{\sigma}^2 = S^2$ 分别为 μ, σ^2 的无偏估计。

附 所以修正的样本方差是方差的渐近无偏估计。

修正的样本方差

$$\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$$

$$E(\tilde{S}^2) = \frac{n-1}{n} E(S^2)$$

$$= \frac{n-1}{n} \sigma^2 \rightarrow \sigma^2 \quad (n \rightarrow \infty)$$
 即 $\tilde{S}^2$ 是 σ^2 的 **渐近无偏估计**

单正态总体 期望的矩估计和 MLE 是 μ 的无偏估计, 而方差的矩估计和 MLE (形同修正的样本方差, 除以 n 那个) 是方差的有偏 (渐近无偏) 估计。

证明 算得形式后应用上述结论。

总体 $X \sim U(0, \theta)$ ($\theta > 0$) 关于 θ 矩估计和 MLE 的无偏性。

解 $\because E(X) = \theta/2$, 令 $\bar{X} = \theta/2$
 求得 θ 的矩估计为 $\hat{\theta}_M = 2\bar{X}$
 $\because E(\hat{\theta}_M) = 2E(\bar{X}) = 2E(X) = 2 \cdot \frac{\theta}{2} = \theta$
 $\therefore \theta$ 的矩估计 $\hat{\theta}_M = 2\bar{X}$ 是 θ 的无偏估计

似然函数为

$$L(\theta) = \frac{1}{\theta^n} \quad (0 < X_1, \dots, X_n < \theta)$$
 $\therefore L(\theta)$ 关于 θ 单调递减
 $\therefore \theta$ 的 MLE 为 $\hat{\theta}_L = X_{(n)} = \max_{1 \leq i \leq n} X_i$.
● 怎样计算 $E(\hat{\theta}_L)$?
分析 $F_{\max}(z) = [F(z)]^n \Rightarrow f_{\max}(z) = nf(z)[F(z)]^{n-1}$
 $\Rightarrow E(\hat{\theta}_L) = \int_{-\infty}^{\infty} z \cdot f_{\max}(z) dz$

又 $X_{(n)} = \max_{1 \leq i \leq n} X_i$ 的密度函数为

$$f_{\max}(z) = \begin{cases} n \frac{1}{\theta} \left(\frac{z}{\theta} \right)^{n-1}, & 0 < z < \theta \\ 0, & \text{其它} \end{cases} = \begin{cases} n \frac{1}{\theta} \left(\frac{z}{\theta} \right)^{n-1}, & 0 < z < \theta \\ 0, & \text{其它} \end{cases}$$
 $\therefore E(\hat{\theta}_L) = \int_{-\infty}^{\infty} z \cdot f_{\max}(z) dz$

$$= \int_0^{\theta} z \cdot n \frac{1}{\theta} \left(\frac{z}{\theta} \right)^{n-1} dz = \frac{n}{n+1} \theta < \theta$$
 $\therefore \hat{\theta}_L = X_{(n)}$ 是 θ 的有偏估计 (渐近无偏估计). 经修正后

$$\hat{\theta} = \frac{n+1}{n} \hat{\theta}_L = \frac{n+1}{n} X_{(n)}$$
 是 θ 的无偏估计.

* 有效性

* 概念

$$\text{均方误差 } E_{\theta}[(\hat{\theta} - \theta)^2] = D(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2$$

有效 都是无偏估计, 对任意 θ , 哪个的方差小于或等于另一个哪个更有效。

* 实例

总体 $X \sim U(0, \theta) (\theta > 0)$ 前述两个无偏估计 (矩估计和修正的 MLE) 的有效性

$$\begin{aligned} \text{解 } D_{\theta}(\hat{\theta}_M) &= 4 \cdot D_{\theta}(\bar{X}) \\ &= 4 \cdot \frac{D_{\theta}(X)}{n} = 4 \cdot \frac{\theta^2}{12n} = \frac{\theta^2}{3n} \\ D_{\theta}(\hat{\theta}) &= \frac{(n+1)^2}{n^2} D_{\theta}(X_{(n)}) \\ &= \frac{(n+1)^2}{n^2} \int_0^{\theta} (z - \frac{n}{n+1}\theta)^2 \frac{n}{\theta} \left(\frac{z}{\theta}\right)^{n-1} dz = \frac{\theta^2}{n(n+2)} \end{aligned}$$

当 $n > 1$ 时, $\forall \theta > 0$ 有

$$D_{\theta}(\hat{\theta}) < D_{\theta}(\hat{\theta}_M)$$

故 $\hat{\theta}$ 较 $\hat{\theta}_M$ 有效.

* 相合性 (一致性)

* 概念

$$\text{相合估计 } \hat{\theta}_n \xrightarrow{P} \theta (n \rightarrow \infty)$$

* 实例

任意期望与方差存在的分布 其样本均值和样本方差为期望和方差的相合估计。

$$\begin{aligned} \text{证 由辛钦大数定律知} \\ \bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu (n \rightarrow \infty) \\ S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n(\bar{X})^2 \right) \\ &= \frac{n}{n-1} \cdot \frac{1}{n} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} (\bar{X})^2 \\ &\xrightarrow{P} E(X^2) - \mu^2 = \sigma^2 \end{aligned}$$

* 一般结论

◇ θ 的矩估计是相合估计

◆ 由辛钦大数定律

◇ θ 的 MLE 一般也是相合估计

◇ 相合估计不一定是无偏估计

◇ 估计量方差趋于 0 时是相合估计 (充分条件)

$$\text{若 } \hat{\theta} \text{ 是 } \theta \text{ 的无偏估计, 则由切比雪夫不等式有}$$

$$P\{|\hat{\theta} - \theta| \geq \varepsilon\} \leq \frac{D(\hat{\theta})}{\varepsilon^2}$$

故当 $\lim_{n \rightarrow \infty} D(\hat{\theta}) = 0$ 时 $\hat{\theta}$ 是 θ 的相合估计 (充分条件).

* 相合估计是对估计量最基本的要求, 它代表了“样本容量越大估计越精确”。

* 综合实例

例 设 $X_1, X_2, \dots, X_n$ 为总体 $X \sim b(m, p)$ ($0 < p < 1$) 的样本, 求未知参数 p 的 MLE $\hat{p}$, 试证 $\hat{p}$ 是 p 的无偏估计与相合估计.

解 似然函数为

$$\begin{aligned} L(p) &= \prod_{i=1}^n C_m^{X_i} p^{X_i} (1-p)^{m-X_i} \\ &= \left(\prod_{i=1}^n C_m^{X_i} \right) \cdot p^{\sum_{i=1}^n X_i} \cdot (1-p)^{\sum_{i=1}^n (m-X_i)} \\ &= \left(\prod_{i=1}^n C_m^{X_i} \right) \cdot p^{n\bar{X}} \cdot (1-p)^{mn-n\bar{X}} \end{aligned}$$

令 $\frac{\partial \ln L}{\partial p} = \frac{n\bar{X}}{p} - \frac{mn-n\bar{X}}{1-p} = 0$, 求得 p 的 MLE 为 $\hat{p} = \frac{\bar{X}}{m}$

$$\therefore E(\hat{p}) = \frac{E(\bar{X})}{m} = \frac{mp}{m} = p$$

$$\hat{p} = \frac{\bar{X}}{m} \xrightarrow{P} \frac{mp}{m} = p \quad (n \rightarrow \infty)$$

$\therefore \hat{p} = \frac{\bar{X}}{m}$ 是 p 的无偏估计与相合估计.

C7§3 区间估计.

* 做法:

取未知参数的一个良好点估计 $\hat{\theta}$ (记号...)

取枢轴量 W $\rightarrow$ 分布不依赖于任何未知参数, 且取单值统计量的真值.

确定置信水平 $1-\alpha$.

由 $P(a \leq W \leq b) = 1-\alpha$ 计算 a, b .

真值 θ 落在 (a, b) 中概率为 $1-\alpha$.

区间 $a \leq W \leq b \Rightarrow \underline{\theta} \leq \theta \leq \bar{\theta}$.

* 区间并不唯一, 越短越好 $\leftarrow$ 跟点估计期望中心取的好不好.

* 各类情况:

	待估参数	其它参数	枢轴变量(pivotal quantity)及其分布
一个正态总体	μ	σ^2 已知	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$
	μ	σ^2 未知	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$
	σ^2	μ 已知	$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$
	σ^2	μ 未知	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
两个正态总体	$\mu_1 - \mu_2$	σ_1^2, σ_2^2 已知	$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$
	$\mu_1 - \mu_2$	$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知	$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$
	σ_1^2 / σ_2^2	μ_1, μ_2 未知	$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$
	σ_1^2 / σ_2^2	μ_1, μ_2 已知	$\frac{\sum_{i=1}^{n_1} \left(\frac{X_i - \mu_1}{\sigma_1} \right)^2 / n_1}{\sum_{i=1}^{n_2} \left(\frac{Y_i - \mu_2}{\sigma_2} \right)^2 / n_2} \sim F(n_1, n_2)$

$\leftarrow$ 不可用 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ 作 σ^2 再平方, 符号不对.
(要 $\sigma^2 \rightarrow \sigma \rightarrow \sigma^2$).

$\leftarrow \bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$.

$S_w^2 = [(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2] / (n_1 + n_2 - 2)$
 $S_w = \sqrt{S_w^2}$

★ 全已知: 正态分布.

σ 未知: χ^2 分布.

任 σ^2 : F 分布. (σ^2 / σ^2 则 F 分布).

$\leftarrow \mu$ 已知 $\rightarrow$ 用 F 定义

μ 未知 $\rightarrow$ 用定理

* 单侧置信区间.

* 单侧置信下限 $\underline{\theta}$: $P\{\underline{\theta} < \theta\} = 1-\alpha$.

* 单侧置信上限 $\bar{\theta}$: $P\{\theta < \bar{\theta}\} = 1-\alpha$.

* 注意上/下, 正/负. 区间变换后可能变号.

C2S1 假设检验概述

* 原假设 H_0 , 备择(对立)假设 H_1 .

一般符号 $(=, <, >)$ 保守的, 先假设成立
由此计算样本发生的概率 $\Rightarrow$ 若为小概率事件, 则倾向于怀疑 H_0 本身
拒绝 H_0
即 H_1 成立对应
好假说反证法
假说反证法成立, 则 H_0 中应假设其不成立
双侧假设检验: $H_0: \theta = \theta_0 \leftrightarrow H_1: \theta \neq \theta_0$
右: $H_0: \theta \leq \theta_0 \leftrightarrow H_1: \theta > \theta_0$
左: $H_0: \theta \geq \theta_0 \leftrightarrow H_1: \theta < \theta_0$

* 选取检验统计量 T . (类似于测量量)

* 拒绝域 $R \rightarrow$ 使 H_0 被拒绝的样本组成的区域. 最后代入样本, 看是否在其中则拒绝 H_0 .

* 确定显著性水平 α .

I 类错误: 弃真 $\rightarrow P(I) = P(\text{拒绝 } H_0 | H_0 \text{ 为真})$ 先使 $P(I) \leq$ 某个常数 α 显著性水平

II 类错误: 取伪 $\rightarrow P(II) = P(\text{接受 } H_0 | H_0 \text{ 为假})$ 再使 $P(II)$ 尽量小

* 先保 $P(I)$ 低再保 $P(II)$ 低 $\Rightarrow$ 将显著性检验
 $\rightarrow$ 导致了 H_0 和 H_1 不对等 $\Rightarrow$ 对 H_0 有保护倾向


* 确定拒绝域 R 的临界值.

$\rightarrow$ 使 $P(I) = P(\text{拒绝 } H_0 | H_0 \text{ 为真}) = P(\text{拒绝 } H_0) = P(T \in R) = \alpha$

* P.C. 因未假设 H_0 成立, 故 H_0 中符号代表的关系成立, 故参数假设为已知

$$P\left\{\frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} > u_{1-\alpha} \mid H_0 \text{ 真} \right\} \leq P\left\{\frac{\bar{X} - \mu}{\sigma_0 / \sqrt{n}} > u_{1-\alpha} \mid \mu \leq \mu_0 \right\} \leq P\left\{\frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} > u_{1-\alpha} \mid \mu = \mu_0 \right\} = \alpha$$

$H_0: \mu = \mu_0$ 的拒绝域
如果 $\frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} > u_{1-\alpha}$ 作为 H_0 的拒绝域, 其 I 类风险不超过 α
从直观上看: 两点之间的距离越大越容易分辨



单边假设检验问题, 检验统计量都采用临界点处的分布

* 检验统计量表征一种从样本中提取出来的特征, 这个特征具有自己的分布。

该特征 (统计量) 具有两重性, 首先作为随机变量有其期望等:
即若分布的参数真的是预想的那样, 期望值为统计量的预测值 (无偏估计就是说这个预测值等于真值);

其次作为具体值是用已知的样本算出来的测量值 (观测值), 将该测量值与预测值比较,
就可知样本是不是真的像我们假设的那样分布, 由此检验参数的正确性:
如果超出了接受范围 (进入拒绝域), 则说明原假设存疑, 由此拒绝之。

所以, 为了能顺利计算检验统计量的期望和实际值, 要求它包含的参数我们都已知。
抽样分布定理就是提供了几种较好的统计量形式, 适用于不同情况 (某些量未知的情况)。

当所有量皆已知时, 理论上有好几条定理里的统计量都可以拿来用。
比如单正态总体已知方差估计均值时, 可以直接用标准正态分布; 也可以用样本方差替代总体方差; 可以得出不一样的区间估计结果。
但由于其包含的信息量不同——如引入总体方差必然包含更多的先验信息——得到的估计精确度也会不同:
t-分布曲线比正态分布平缓, 所得估计区间肯定宽那么一些。

比如要求分位点, 已知正态分布时如果再用切比雪夫不等式, 能框出的范围总会更模糊——因为信息量的减少。

C2S2 正态总体的假设检验

基本同前, 略

附录 1 常用分布的分布及数字特征

分布类型	分布名称	分布律或密度函数	数学期望	方差
离散型	0-1 分布 $B(1, p)$	$P(X=k)=p^k (1-p)^{1-k}, 0<p<1, k=0, 1$	p	pq
	二项分布 $B(n, p)$	$P(X=k)=\binom{n}{k} p^k (1-p)^{n-k},$ $0<p<1, k=0, 1, \dots, n$	np	npq
	超几何分布 $H(N, M, n)$	$P(X=k)=\frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}},$ $k=\max(0, n+M-N), \dots, \min(n, M)$	$n \frac{M}{N}$	$\frac{nM(N-M)(N-n)}{N^2(N-1)}$
	泊松分布 $P(\lambda)$	$P(X=k)=\frac{\lambda^k}{k!} e^{-\lambda},$ $\lambda>0, k=0, 1, 2, \dots, n, \dots$	λ	λ
	几何分布 $Ge(p)$	$P(X=k)=p(1-p)^{k-1},$ $0<p<1, k=1, 2, \dots, n, \dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
	负二项分布 $NB(r, p)$	$P(X=k)=\binom{k-1}{r-1} p^r (1-p)^{k-r},$ $0<p<1, k=r, r+1, \dots, r+n, \dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
连续型	均匀分布 $U(a, b)$	$f(x)=\begin{cases} \frac{1}{b-a}, & a<x<b, \\ 0, & \text{其他} \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
	指数分布 $E(\lambda)$	$f(x)=\begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & \text{其他} \end{cases} \lambda>0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
	正态分布 $N(\mu, \sigma^2)$	$f(x)=\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty<x<+\infty \quad \mu \in R, \sigma>0$	μ	σ^2
	伽马分布 $Ga(a, \lambda)$	$f(x)=\frac{\lambda^a}{\Gamma(a)} x^{a-1} e^{-\lambda x}, x \geq 0, \lambda>0, a>0$	$\frac{a}{\lambda}$	$\frac{a}{\lambda^2}$
	贝塔分布 $Be(a, b)$	$f(x)=\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, 0<x<1, a>0, b>0$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$

附录 2 二维离散型随机变量和连续型 随机变量相关定义的对照

(1) 分布函数 $F(x, y) = P(X \leq x, Y \leq y)$

离散型
$$F(x, y) = \sum_{i: x_i \leq x} \sum_{j: y_j \leq y} p_{ij}.$$

连续型
$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv.$$

(2) 分布律或密度函数

离散型 $P(X=x_i, Y=y_j) = p_{ij}$:

① 非负性 $p_{ij} \geq 0, i, j=1, 2, \dots$;

② 规范性 $\sum_i \sum_j p_{ij} = 1.$

连续型 $f(x, y)$:

① 非负性 $f(x, y) \geq 0, -\infty < x, y < +\infty$;

② 规范性 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1.$

(3) 边缘分布函数 $F_X(x) = F(x, +\infty)$

离散型
$$F_X(x) = \sum_{i: x_i \leq x} \sum_{j=1}^{\infty} p_{ij}.$$

连续型
$$F_X(x) = \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(u, y) dy \right] du.$$

(4) 边缘分布律或边缘密度函数

离散型
$$p_{i \cdot} = P(X=x_i) = \sum_j p_{ij}.$$

连续型
$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy.$$

(5) 相互独立性: 对任意 $x, y \in R$, 都有 $F(x, y) = F_X(x) F_Y(y)$

离散型 对任意的 $i, j=1, 2, \dots$, 都有 $p_{ij} = p_{i \cdot} \cdot p_{\cdot j}$.

连续型 在 $f(x, y)$, $f_X(x)$ 及 $f_Y(y)$ 的一切公共连续点上都有 $f(x, y) = f_X(x) \cdot f_Y(y)$.

(6) 条件分布函数 $F_{X|Y}(x|y) = P(X \leq x | Y = y)$

离散型 $F_{X|Y}(x|y_j) = \frac{\sum_{i: x_i \leq x} p_{ij}}{p_{.j}}.$

连续型 $F_{X|Y}(x|y) = \frac{\int_{-\infty}^x f(u, y) du}{f_Y(y)}, \quad -\infty < x < +\infty.$

(7) 条件分布律或条件密度函数

离散型 $P(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{.j}}, \quad i = 1, 2, \dots, p_{.j}.$

连续型 $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad -\infty < x < +\infty, \quad \text{其中 } f_Y(y) > 0.$